

II. Introduction au parallélisme par échange de message via MPI

1) Écrire son premier programme MPI

Cours et matériel supplémentaires sur internet



Selon moi, le cours le plus complet sur MPI en français et anglais:

<http://www.idris.fr/formations/mpi/>

Les implémentations fournissent en général une documentation en ligne complète :

<https://www.open-mpi.org/>

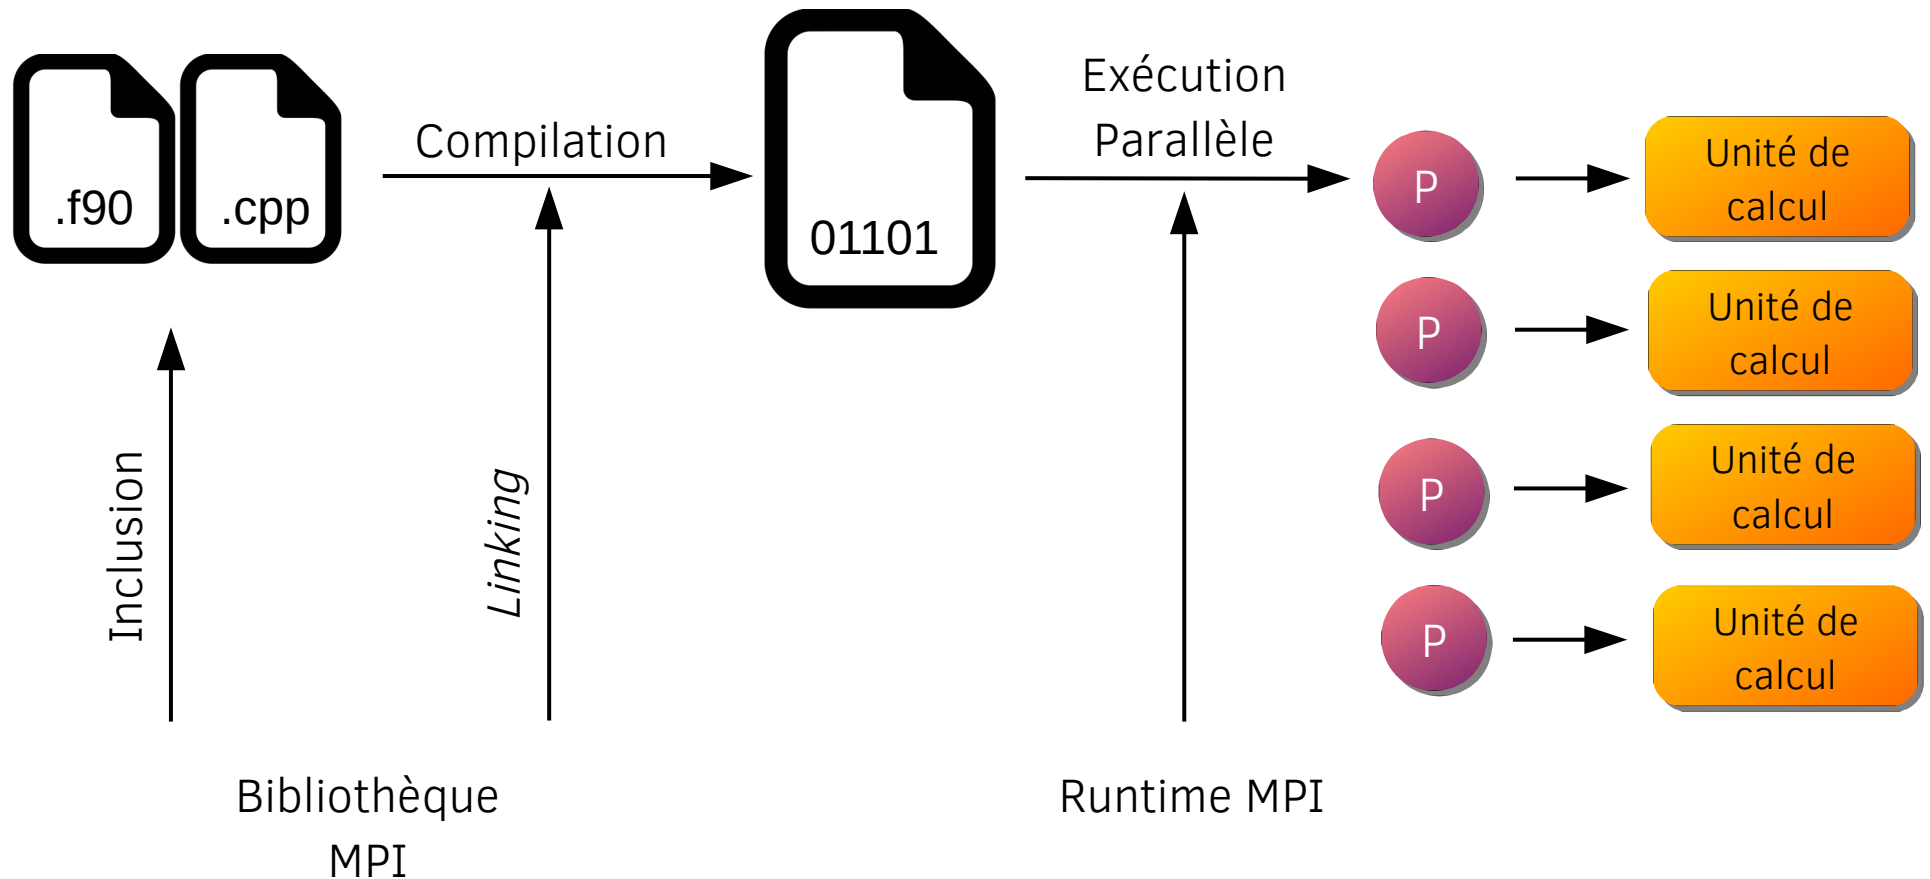
<https://www.mcs.anl.gov/research/projects/mpi/learning.html>

<http://mpi.deino.net/>

La chaîne de compilation et d'exécution d'un programme MPI

Programme parallèle avec
appel aux fonctions MPI

Fichier
exécutable



Implémentations MPI



Implémentations libres que vous pouvez vous procurer pour vos ordinateurs :

- OpenMPI
- MPICH
- Deino

Implémentation propriétaire :

- IntelMPI

Disponible en Fortran, C, C++, Python



L'installation peut se faire par les sources ou via `apt-get install`

Compilation d'un programme MPI (Fortran)

La compilation fait appel au **wrapper MPI mpif90**. Le wrapper utilise le compilateur Fortran par défaut (par exemple gfortran) en y ajoutant des options de compilation supplémentaires et les chemins vers la bibliothèque MPI.

Pour connaître le contenu du wrapper :



```
> mpif90 -show
```

Pour compiler :



```
> mpif90 program.f90 -o executable
```

Exécution d'un programme MPI

- L'exécution se fait par l'intermédiaire de la commande `mpirun`.
- `-np` représente le **nombre de processus MPI à lancer**.
- Si le nombre de processus MPI est inférieur au nombre d'unités de calcul disponible, chaque processus est exécuté par une unité indépendante
- Il est possible de lancer plus de processus MPI que d'unités de calcul, dans ce cas, les ressources sont partagées.

Pour exécuter votre code en ligne de commande :




```
> mpirun -np 6 ./executable
```

Démarrage d'un programme MPI : notion de communicateur

Communicator

- Un **communicateur** est un ensemble de processus MPI capable de communiquer entre eux.
- Au sein d'un communicateur, chaque processus MPI est représenté par **un rang (*rank*) unique sous forme d'un entier**.
- Le communicateur par défaut regroupe l'**ensemble des processus** et se nomme **MPI_COMM_WORLD**.


```
> mpirun -np 4 ./eexecutable
```



MPI_COMM_WORLD : Communicateur
composé de 4 rangs

Démarrage d'un programme MPI (Fortran) : inclure MPI

La première étape consiste à ne pas oublier d'**inclure le module MPI** (header en C/C++)



.f90

```
Program test
```

```
Use mpi
```

```
...
```

```
End program
```


Démarrage d'un programme MPI (Fortran) : initialiser et finaliser MPI

- MPI est une bibliothèque qui fonctionne par **appel à des fonctions** (subroutine en Fortran)
- La deuxième étape importante est l'**initialisation de MPI**
- Il ne faut pas oublier de **finaliser pour finir son programme proprement**



.f90

```
Program test

Use mpi

Implicit none
Integer :: provided
Integer :: ierror

Call MPI_INIT(ierror)

...

Call MPI_FINALIZE(ierror)

End program
```

Démarrage d'un programme MPI (Fortran) : initialiser MPI

- L'initialisation se fait avec la fonction **MPI_INIT**.
- Toute fonction MPI renvoie en **dernier argument un code d'erreur noté ici *ierror***.



```
Call MPI_INIT(ierror)
```

.f90

- Le code d'erreur permet si besoin de vérifier qu'un appel s'est bien déroulé



https://www.open-mpi.org/doc/v1.8/man3/MPI_Init.3.php

Démarrage d'un programme MPI (Fortran) : finaliser MPI

- La finalisation se fait avec la fonction **MPI_FINALIZE**.
- Elle est appelée à la toute fin du programme



.f90

```
Call MPI_FINALIZE(ierr)
```

Démarrage d'un programme MPI (Fortran) : récupérer le nombre de rangs

- Le **nombre de rangs** dans le communicateur `MPI_COMM_WORLD` se récupère via la fonction `MPI_COMM_SIZE` : c'est le **nombre total de processus** demandé.



.f90

```
...  
Integer :: number_of_ranks  
...  
Call MPI_COMM_SIZE(MPI_COMM_WORLD, number_of_ranks, ierror)
```

- `MPI_COMM_WORLD` : communicateur (ici celui par défaut)
- `Number_of_ranks` : entier renvoyé contenant le nombre de rangs MPI

Démarrage d'un programme MPI (Fortran) : récupérer le rang de chaque processus MPI

- Chaque processus récupère son **rang** dans le communicateur **MPI_COMM_WORLD** via la fonction **MPI_COMM_RANK**.




.f90

```
...  
Integer :: rank  
...  
  
Call MPI_COMM_RANK(MPI_COMM_WORLD, rank, ierror)
```

- MPI_COMM_WORLD** : communicateur (ici celui par défaut)
- rank** : entier renvoyé désignant le rang du processus qui appelle la fonction

Mesure du temps : MPI_WTIME

- **MPI_WTIME** permet de récupérer le temps écoulé sur le processus courant en seconde



.f90

```
Real :: time  
Time = MPI_WTIME()
```

- Par deux appels et une soustraction, cette fonction permet de déterminer le **temps passer dans une section du code**



.f90

```
Real :: time  
time = MPI_WTIME()  
  
! Des calculs...  
...  
  
! Ce temps est le temps passé entre les deux appels à MPI_WTIME  
time = MPI_WTIME() - time
```



https://www.open-mpi.org/doc/v4.0/man3/MPI_Wtime.3.php

Exercice n°1 : votre premier programme MPI



- Rendez vous sur le Gitlab des exercices :
<https://gitlab.maisondelasimulation.fr/mlobet/cours-hpc-m2-dfe>
- Télécharger les exercices sur votre session de travail
- Décompressez l'archive en ligne de commande



```
> tar xvf archivedossier.tar
```

- Rendez vous dans le dossier de l'exercice n°1 appelé `1_initialization`



```
> cd exercices/mpi/1_initialization
```

- Ouvrez les instructions contenues dans le fichier `README.md` avec votre éditeur de fichier favori (vim, emacs, atom, gedit...)



Vous pouvez lire le README directement depuis le Gitlab et c'est plus confortable comme ça.

Différencier du code pour des processus donnés



Le programme s'exécute simultanément autant de fois qu'il y a de processus parallèle : chaque ligne de code est appelée par chaque processus.

Pour faire en sorte que certaines portions de code soient réservées à certains processus, on utilise des conditions `if` avec le numéro de rang comme condition.



```
If (rank == 1) then  
    ! Cette portion de code ne sera exécutée que par le rang 1  
    ...  
End if
```


Votre premier programme MPI

A ce stade du cours, vous savez maintenant :

- Écrire un programme parallèle simple
- Compiler un programme MPI
- Exécuter un programme MPI
- Récupérer le nombre de rangs et le rang de chaque processus


II. Introduction au parallélisme par échange de message via MPI

2) Les communications point à point bloquantes

Notion de communication point à point

Point to point communication

- L'échange de message constitue la base du concept MPI
- L'échange de message se décompose toujours en **deux étapes** :
 - **Envoi** : Un processus envoie un message à un processus destinataire en spécifiant le rang
 - **Réception** : Un processus doit explicitement recevoir le message en connaissant le rang de l'expéditeur



- — Le processus de rang 0 envoie un message au processus de rang 3
- ➔ Le processus de rang 3 reçoit un message du processus de rang 0

Notion de communication point à point : Envoi de données via SEND


Point to point communication : SEND

- **MPI_SEND** est la fonction appelée par le processus expéditeur



.f90

```
MPI_SEND(message, size, data_type, destination_rank, tag,  
communicator, ierror)
```



https://www.open-mpi.org/doc/v1.8/man3/MPI_Send.3.php

Notion de communication point à point : Envoi de données via SEND

Point to point communication : SEND

- **MPI_SEND** est la fonction appelée par le processus expéditeur



.f90

```
MPI_SEND(message, size, data_type, destination_rank, tag,  
communicator, ierror)
```

- **Message** : la variable contenant le message à envoyer (booléen, entier, double, caractère, chaîne, tableau, structure plus complexe...)
- **Size** : nombre d'éléments constituant le message (> 1 uniquement pour une chaîne ou un tableau)
- **data_type** : type de variable utilisée pour le message (**MPI_INTEGER** pour les integer, **MPI_DOUBLE_PRECISION** pour les `real(8)`, **MPI_REAL** pour les `real(4)`...)
- **Tag** : numéro attribué à la communication si plusieurs coms vers le même processus
- **destination_rank** : rang du processus destinataire



https://linux.die.net/man/3/mpi_real

Exemple d'utilisation de MPI_SEND

Point to point communication : MPI_SEND

- Envoi d'un message de type real(8) au processus de rang 3 par le processus de rang 2



.f90

```
Real(8) :: message
Integer :: tag
Integer :: ierror

Message = 1245.76

If (rank == 2) then

    Call MPI_SEND(message, 1, MPI_DOUBLE_PRECISION, 3, tag, &
                  MPI_COMM_WORLD, ierror)

End if
```

Exemple d'utilisation de SEND

Point to point communication : SEND

- Envoi d'un message de type tableau contenant 5 entiers au processus de rang 6 par le processus de rang 1



.f90

```
Integer, dimension(5) :: message
Integer :: tag
Integer :: ierror

Message = (/ 12,45,37,43,59 /)

If (rank == 1) then

    Call MPI_SEND(message, 5, MPI_INTEGER, 6, tag, &
                  MPI_COMM_WORLD, ierror)

End if
```

Exemple d'utilisation de SEND

Point to point communication : SEND

- Envoi d'un message au processus de rang 6 par le processus de rang 1 de type chaîne de caractère contenant 4 caractères et commençant au deuxième élément du message



.f90

```
character(len=10) :: message
Integer :: tag
Integer :: ierror

Message = « abcdefghij »

If (rank == 1) then

    ! Est envoyé « bcde »
    Call MPI_SEND(message(2), 4, MPI_CHARACTER, 6, tag, &
                  MPI_COMM_WORLD, ierror)

End if
```


Notion de communication point à point : Réception de données via MPI_RECV


Point to point communication : MPI_RECV

- **MPI_RECV** est la fonction appelée par le processus destinataire



.f90

```
MPI_RECV(message, size, data_type, source_rank, tag,  
communicator, status, ierror)
```



https://www.open-mpi.org/doc/v1.8/man3/MPI_Recv.3.php

Notion de communication point à point : Réception de données via MPI_RECV

Point to point communication : MPI_RECV

- **RECV** est la fonction appelée par le processus destinataire



.f90

```
MPI_RECV(message, size, data_type, source_rank, tag,  
communicator, status, ierror)
```

- **Message** : la variable contenant le message à recevoir (booléen, entier, double, caractère, chaîne, tableau, structure plus complexe...)
- **Size** : nombre d'éléments constituant le message (> 1 uniquement pour une chaîne ou un tableau)
- **data_type** : type de variable utilisée pour le message (**MPI_INTEGER** pour les integer, **MPI_DOUBLE_PRECISION** pour les `real(8)`, **MPI_REAL** pour les `real(4)`...)
- **source_rank** : rang du processus expéditeur
- **Status** : état de la communication (en dehors de la portée de ce cours)

Exemple d'utilisation de SEND and RECV

Point to point communication : SEND and RECV

- Envoi d'un message de type real(8) au processus de rang 3 par le processus de rang 2
- Réception d'un message de type real(8) par le rang 2 venant du rang 3



.f90

```
Real(8) :: message
Integer :: tag
Integer :: ierror

If (rank == 2) then

    Message = 1245.76

    Call MPI_SEND(message, 1, MPI_DOUBLE_PRECISION, 3, tag, &
                  MPI_COMM_WORLD, ierror)

End if

If (rank == 3) then

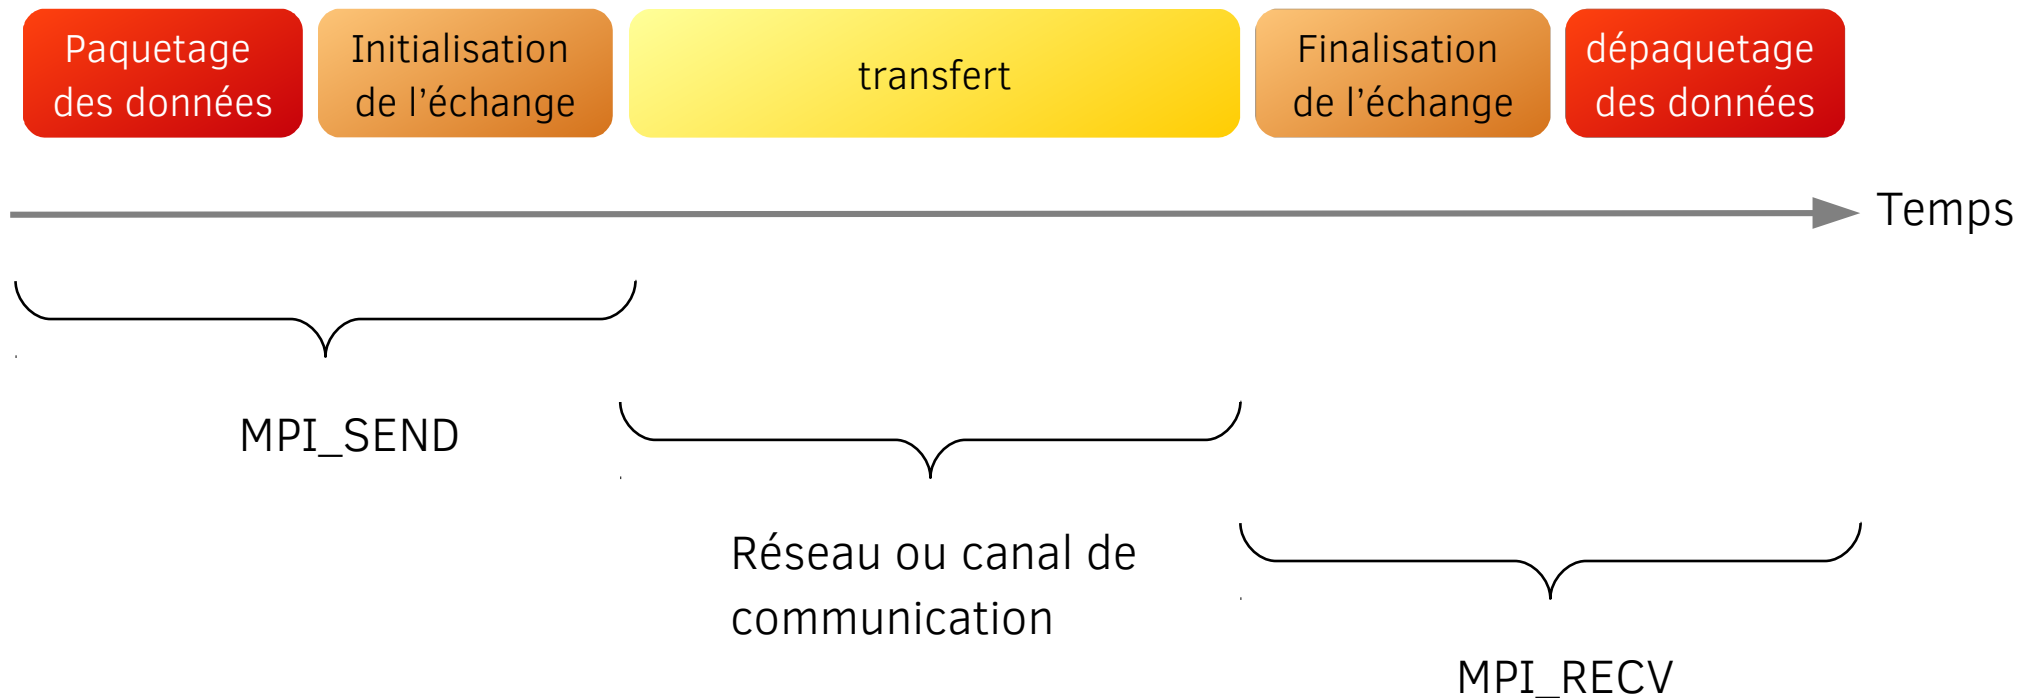
    Call MPI_RECV(message, 1, MPI_DOUBLE_PRECISION, 2, tag, &
                  MPI_COMM_WORLD, MPI_STATUS_IGNORE, ierror)

End if
```

Mieux comprendre une communication

Point to point communication : SEND and RECV

- Une communication se compose d'un ensemble de sous-étapes :



Exercice n°2 : Utilisation des communications point à point



- Rendez vous dans le dossier de l'exercice n°2 appelé 2_blocking_com




```
> cd exercises/mpi/2_blocking_com
```

- Ouvrez les instructions contenues dans le fichier **README.md** avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

Communication point à point : SENDRECV

Point to point communication

- Il est parfois nécessaire de faire un **échange mutuel** de données. Pour ce faire, il existe une fonction qui **allie l'envoi et la réception** : **SENDRECV**.



Le processus de rang 0 envoie et reçoit un message au processus de rang 3

Le processus de rang 3 envoie et reçoit un message du processus de rang 0

Communication point à point : SENDRECV


Point to point communication : SENDRECV

- **SENDRECV** est appelée par les processus expéditeur et destinataire en même temps



.f90

```
MPI_SENDRECV(  
  send_message, send_size, send_type, destination, send_tag, &  
  recv_message, recv_size, recv_type, source, recv_tag, &  
  communicator, status, ierror)
```



https://www.open-mpi.org/doc/v1.8/man3/MPI_Sendrecv.3.php

Exemple d'utilisation de SENDRECV

Point to point communication : SENDRECV

- Envoi et réception d'un message de type real(8) au processus de rang 3 par le processus de rang 2
- Envoi et réception d'un message de type real(8) par le rang 2 venant du rang 3



```
Real(8) :: send_message
Real(8) :: recv_message
Integer :: send_tag
Integer :: recv_tag
Integer :: ierror

If (rank == 2) then

    send_message = 1245.76

    Call MPI_SENDRECV(send_message, 1, MPI_DOUBLE_PRECISION, 3, send_tag, &
                      recv_message, 1, MPI_DOUBLE_PRECISION, 3, recv_tag, &
                      MPI_COMM_WORLD, MPI_STATUS_IGNORE, ierror)

End if

If (rank == 3) then

    send_message = 4567.32


    Call MPI_SENDRECV(send_message, 1, MPI_DOUBLE_PRECISION, 2, send_tag, &
                      recv_message, 1, MPI_DOUBLE_PRECISION, 2, recv_tag, &
                      MPI_COMM_WORLD, MPI_STATUS_IGNORE, ierror)

End if
```


Communication point à point : SENDRECV pour les communications chaînées

Point to point communication

- La fonction **SENDRECV** est également nécessaire pour effectuer des **communications chaînées**
- L'utilisation de **SEND** et **RECV** nécessiterait de gérer manuellement les synchronisations



Chaque processus reçoit un élément d'un processus A et envoie des données à un processus B distinct.



Lorsqu'une communication n'arrive pas à son terme, le programme attend et peut rester figé.

Exercice n°3 : Chaîne ou anneau de communication




- Rendez vous dans le dossier de l'exercice n°3 appelé 3_sendrecv



```
> cd exercises/mpi/3_sendrecv
```

- Ouvrez les instructions contenues dans le fichier **README.md** avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

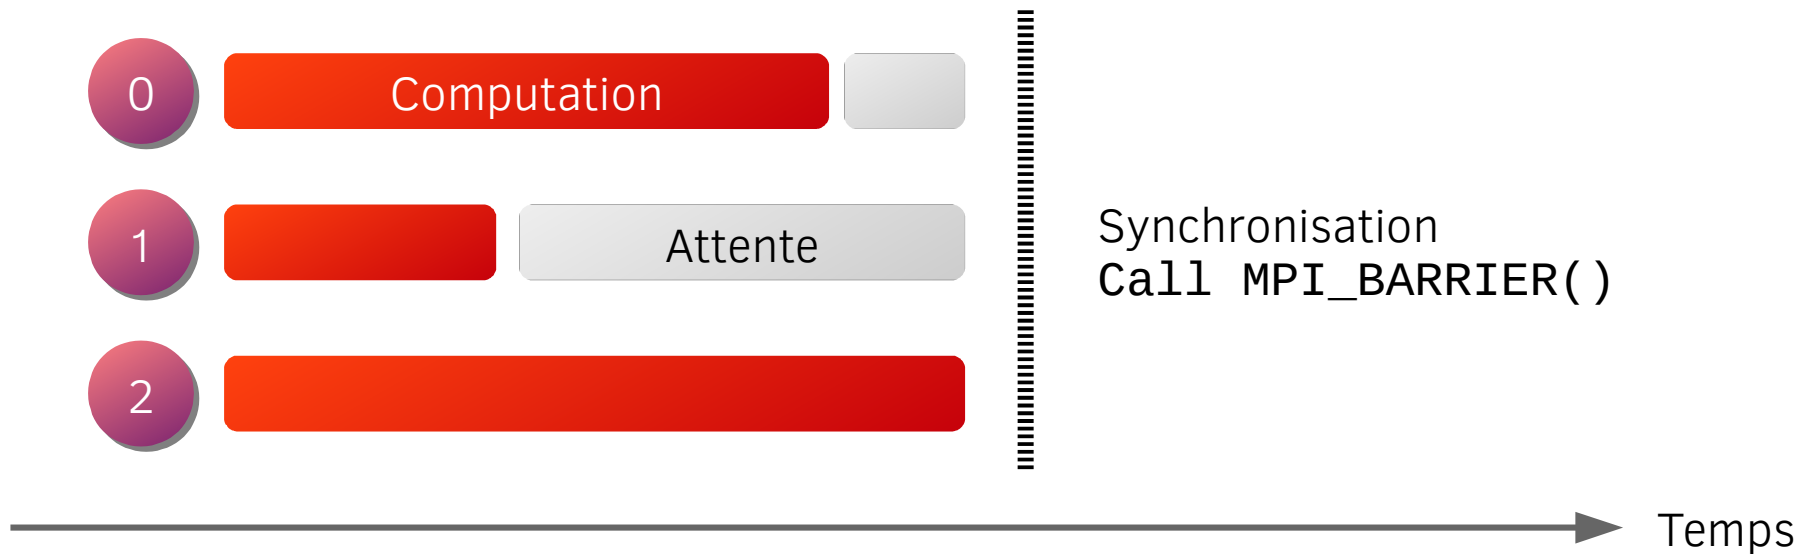


Anneau de
communication

Notion de barrière explicite

Explicit barrier

- Il est parfois nécessaire d'imposer une **étape de synchronisation ou barrière** qui ne sera pas franchie tant que tous les processus ne seront pas arrivés à ce niveau
- La fonction **MPI_BARRIER** est une **manière explicite d'exiger cette synchronisation** dans le code

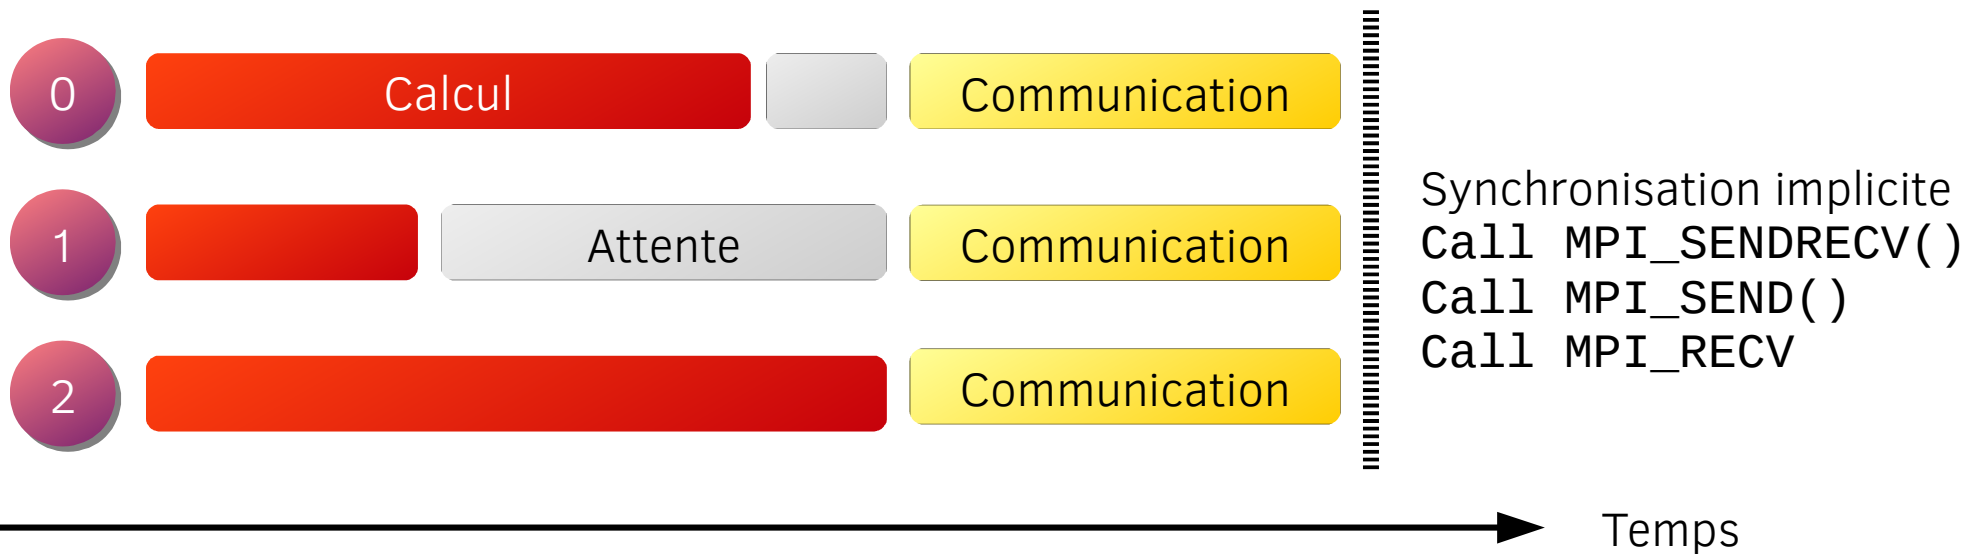


https://www.open-mpi.org/doc/v1.5/man3/MPI_Barrier.3.php

Notion de barrière implicite

Implicit barrier

- Certaines fonctions d'échange induisent des barrières implicites au niveau des processus concernés
- C'est le cas de `MPI_SEND`, `MPI_RECV`, `MPI_SENDRECV` d'où l'appellation de *communication bloquante*



Si certains processus sont en avance, ils effectuent une attente active ou passive. Cette attente est vue comme une perte de ressource.

Communication bloquante : ouverture



Il existe des variantes des communications SEND/RECV permettant diverses optimisations. Ces variantes sont hors de portée de ce cours mais sont très bien décrites dans le cours de l'IDRIS

Premiers échanges MPI

A ce stade du cours, vous savez maintenant :

- Faire communiquer différents processus entre eux
- Gérer des chaînes de communication
- Demander une synchronisation explicite

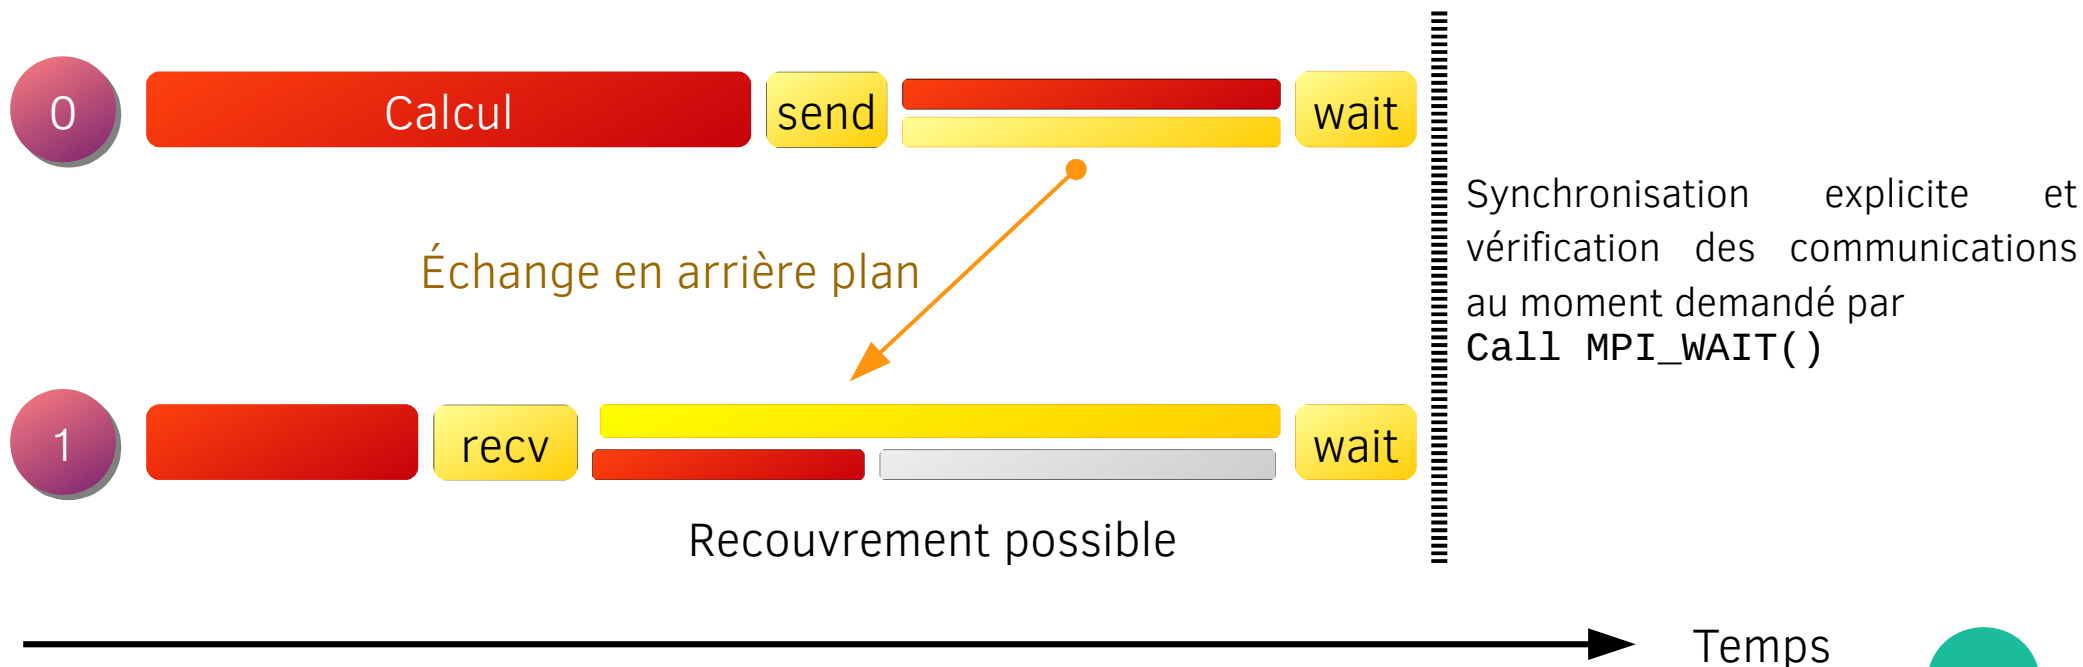
II. Introduction au parallélisme par échange de message via MPI

3) Les communications point à point non-bloquantes

Communication point à point non-bloquante

Implicit barrier

- Les **communications non-bloquantes** permettent d'éviter la **synchronisation implicite** des processus.
- Une **synchronisation explicite** est nécessaire pour s'assurer que les communications ont eu lieu **avant d'utiliser les données échangées**
- Ce type de communication permet de **recouvrir communication et calcul** : envoi et réception en arrière plan



Exercice n°4 : Utilisation des communications non bloquantes



- Rendez vous dans le dossier de l'exercice n°4 appelé 4_nonblocking_com



```
> cd exercises/mpi/4_nonblocking_com
```

- Ouvrez les instructions contenues dans le fichier **README.md** avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

II. Introduction au parallélisme par échange de message via MPI

4) Les communications collectives

Communication collective : les différents types

Collective communication

- Les **communications collectives** sont des communications qui **regroupent en une seule plusieurs communications point à point** entre **plusieurs processus** (voir tout le communicateur).
- 3 types de communication collective :
 - **Synchronisation** : c'est le **MPI_BARRIER**
 - **Transfert** (diffusion, collecte)
 - **Transfert et opérations sur les données** (opération de réduction)




Elles induisent des barrières implicites pour les processus concernés. Pour chaque processus, la barrière est relâchée dès la participation finie.

Communication collective : diffusion générale grâce à MPI_BCAST

Collective communication

- Envoi d'une donnée depuis un processus vers tous les processus du communicateur



Répartition des données
avant l'échange

MPI_Bcast

Nouvelle répartition des
données après l'échange

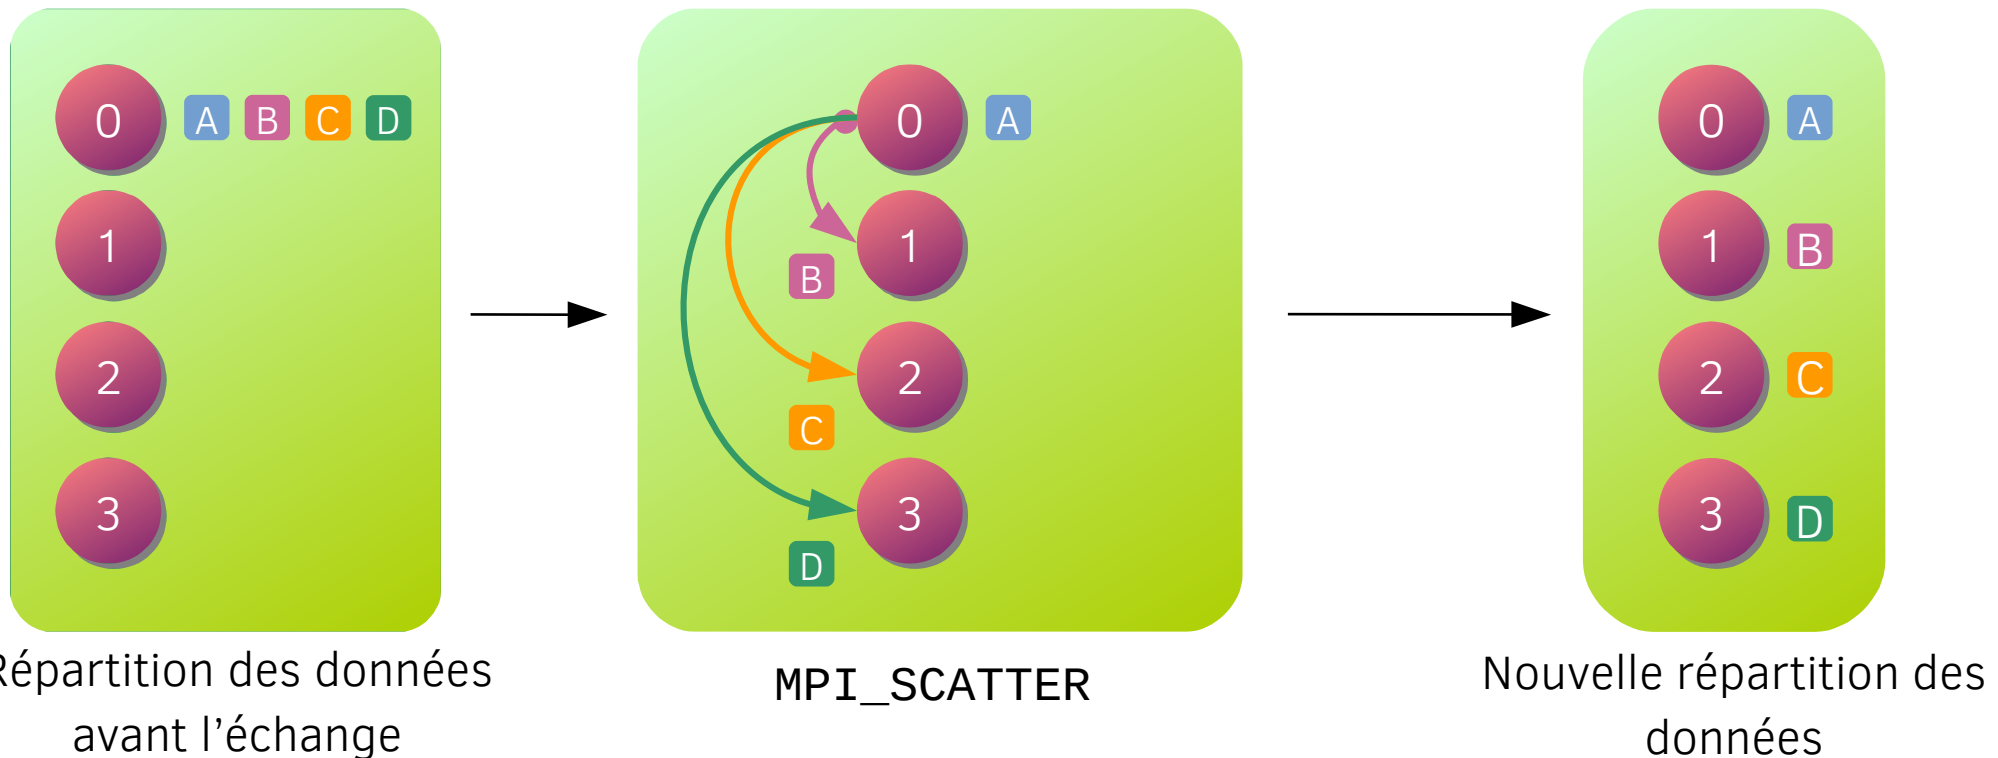


https://www.open-mpi.org/doc/v1.10/man3/MPI_Bcast.3.php

Communication collective : diffusion sélective grâce à MPI_SCATTER

Collective communication

- Partage de données sélectif (selon les critères du développeur) depuis un processus vers tous les processus du communicateur

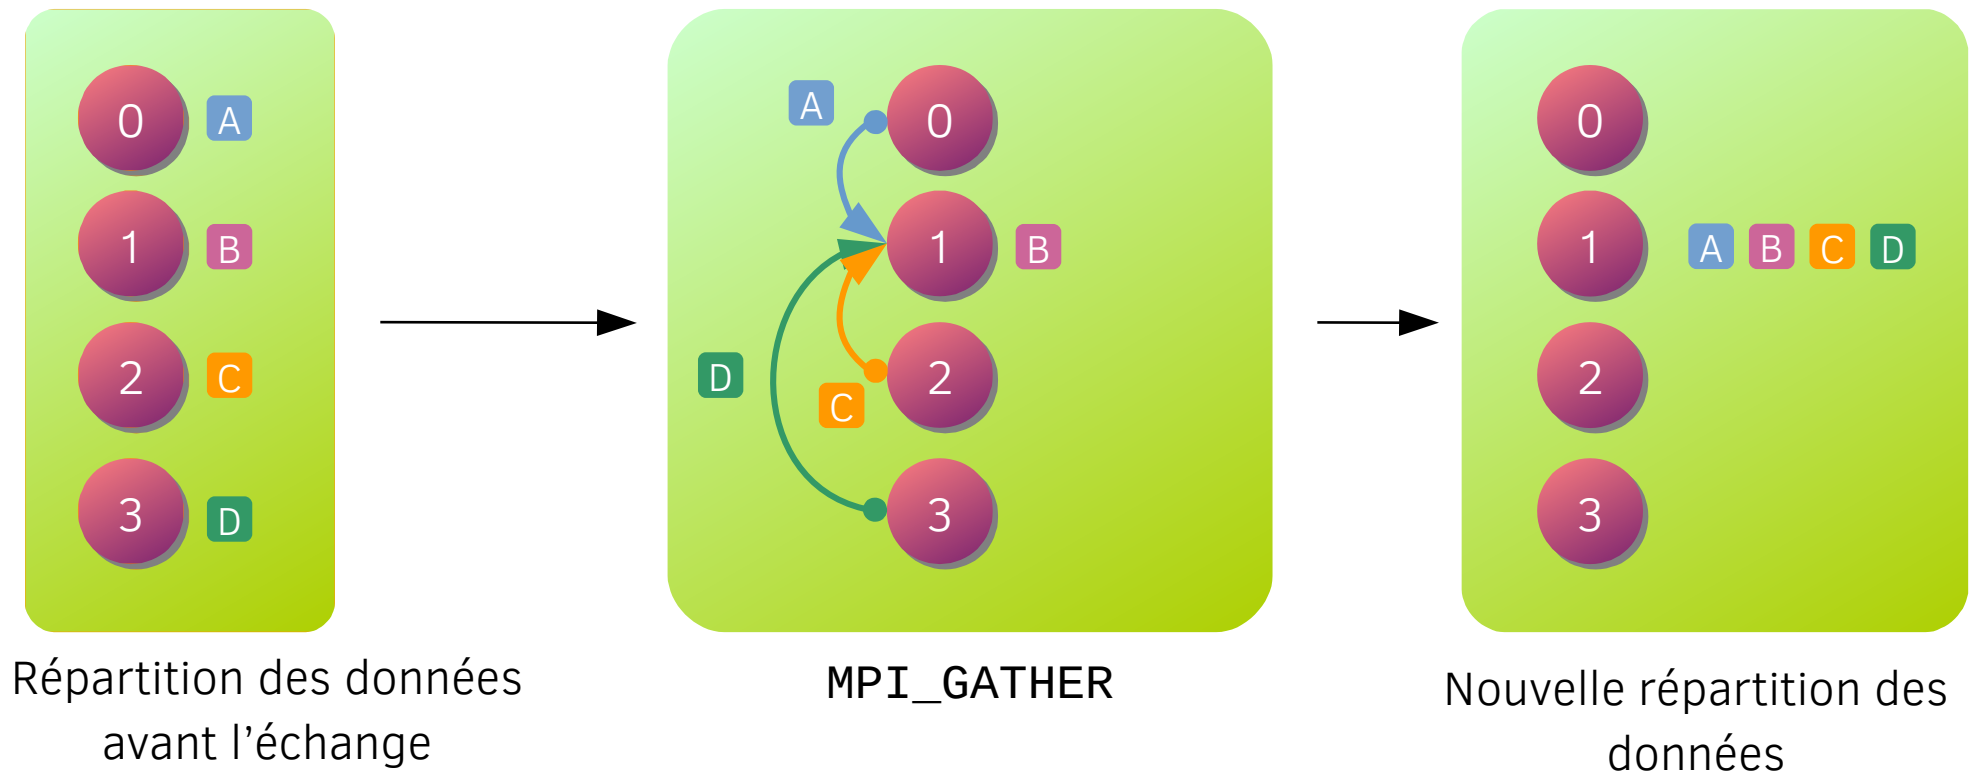


https://www.open-mpi.org/doc/v1.5/man3/MPI_Scatter.3.php

Communication collective : collecte grâce à MPI_GATHER

Collective communication

- Envoi de données réparties sur plusieurs processus vers un processus unique

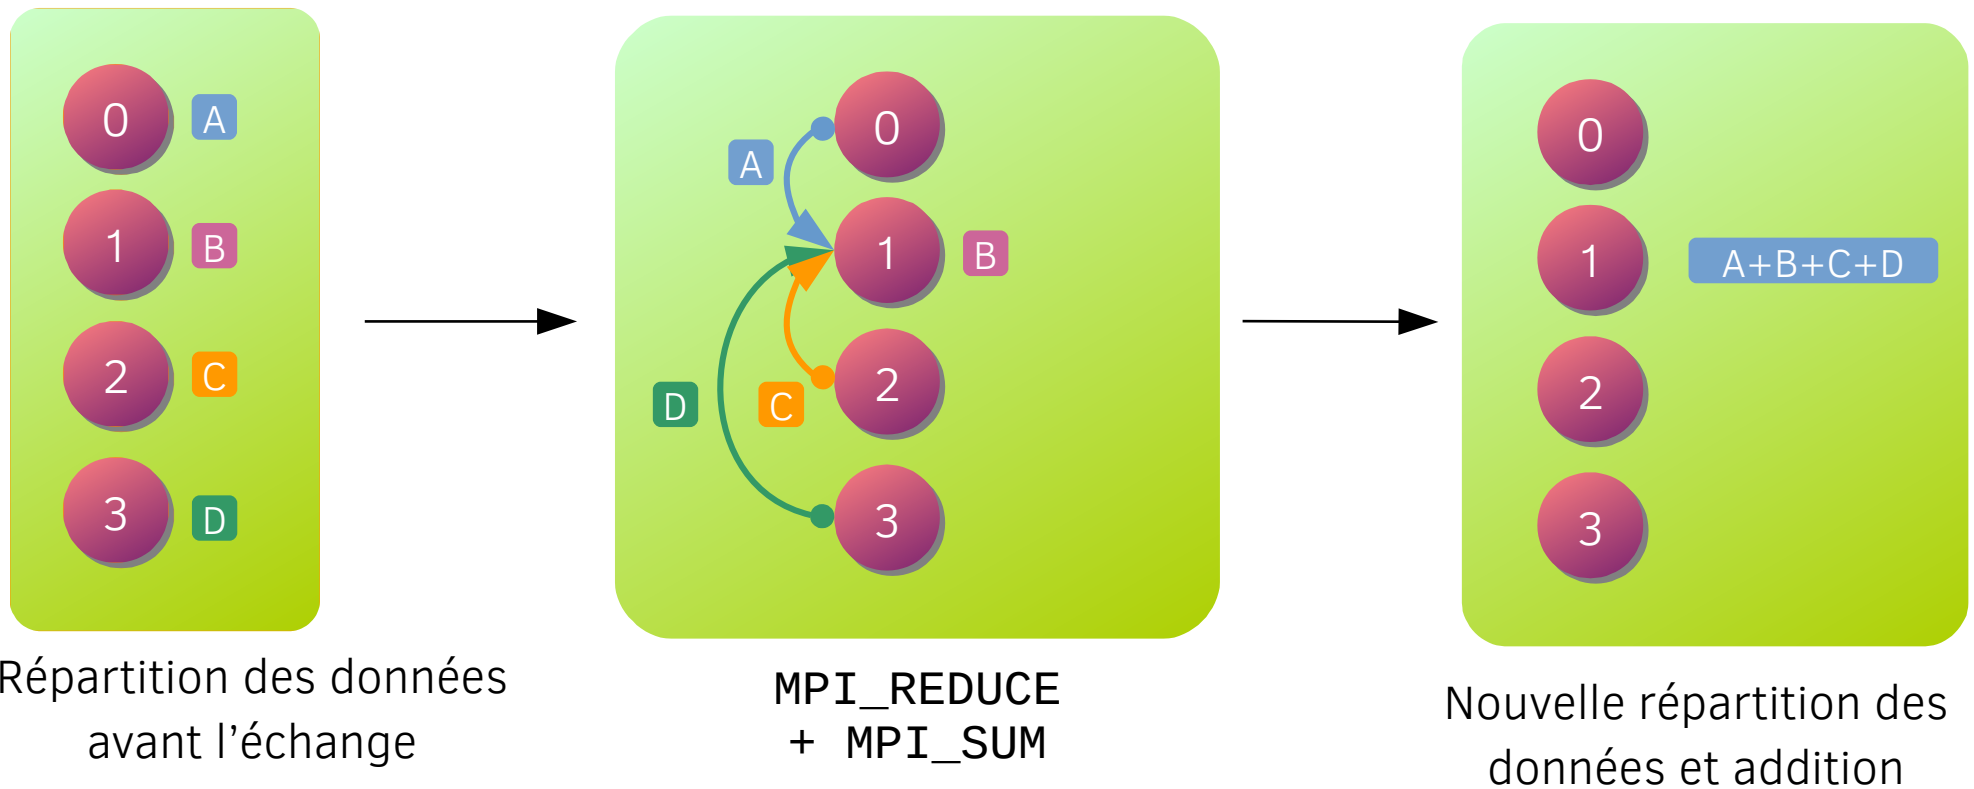


https://www.open-mpi.org/doc/v1.8/man3/MPI_Gather.3.php

Communication collective : réduction grâce à MPI_REDUCE

Collective communication

- Envoi de données réparties sur plusieurs processus vers un seul processus avec une opération de réduction réalisée simultanément



https://www.open-mpi.org/doc/v1.5/man3/MPI_Reduce.3.php

Communication collective : réduction grâce à MPI_REDUCE

Collective communication

- **MPI_REDUCE** est appelée par les processus expéditeurs et destinataires en même temps



.f90

```
MPI_REDUCE(send_value, recv_value, size, MPI_data_type,  
MPI_reduction_operation, destination, communicator, ierror)
```

- **send_value** : la valeur à envoyer par chaque processus
- **recv_value** : la valeur reçue suite aux échanges et à la réduction par le destinataire seulement
- **Size** : nombre d'éléments (>1 si tableau)
- **MPI_data_type** : le type de donnée (ex : **MPI_INTEGER**)
- **MPI_reduction_operation** : type d'opération à effectuer pour la réduction (ex : **MPI_SUM**)
- **Destination** : le processus qui va recevoir les données réduites



https://www.open-mpi.org/doc/v1.5/man3/MPI_Reduce.3.php

Communication collective : opération de réduction

Collective communication

Il existe de multiple opérations de réduction disponibles (`MPI_reduction_operation`) :

- `MPI_SUM` : Somme l'ensemble des données
- `MPI_PROD` : multiplication des données
- `MPI_MAX` : maximum des valeurs
- `MPI_MIN` : minimum des valeurs
- ...



https://www.open-mpi.org/doc/v1.5/man3/MPI_Reduce.3.php

Communication collective : exemple d'utilisation de MPI_REDUCE

Collective communication

- Réduction d'une simple variable réelle double précision



.f90

```
Real(8) :: rank_value
Real(8) :: reduction_value
Integer :: ierror

rank_value = rank

! Addition de l'ensemble des rank_value dans le processus 0

Call MPI_REDUCE(rank_value, reduction_value, 1      &
                MPI_DOUBLE_PRECISION, MPI_SUM, 0, &
                MPI_COMM_WORLD, ierror)
```

Communication collective : exemple d'utilisation de MPI_REDUCE

Collective communication

- Réduction d'un tableau d'entiers avec multiplication de toutes les valeurs



.f90

```
integer, dimension(4) :: rank_value
integer, dimension(4) :: reduction_value
Integer :: ierror

rank_value = (/ 18, 22, 43, 52/)


! Addition de l'ensemble des rank_value dans le processus 0

Call MPI_REDUCE(rank_value, reduction_value, 4      &
                MPI_INTEGER, MPI_PROD, 0,          &
                MPI_COMM_WORLD, ierror)
```


Communication collective : réduction grâce à MPI_ALLREDUCE

Collective communication

- Envoi de données réparties sur plusieurs processus vers tous les processus avec une opération de réduction réalisée simultanément



MPI_ALLREDUCE +
MPI_SUM



Nouvelle répartition des
données et addition



https://www.open-mpi.org/doc/v1.5/man3/MPI_Allreduce.3.php

Communication collective : réduction grâce à MPI_ALLREDUCE

Collective communication

- **MPI_ALLREDUCE** est appelée par les processus expéditeurs et destinataires en même temps



.f90

```
MPI_ALLREDUCE(send_value, recv_value, size, MPI_data_type,  
MPI_reduction_operation, communicator, ierror)
```

- **send_value** : la valeur à envoyer par chaque processus
- **recv_value** : la valeur reçue suite aux échanges et à la réduction par le destinataire seulement
- **Size** : nombre d'éléments (> 1 si tableau)
- **MPI_data_type** : le type de donnée (ex : **MPI_INTEGER**)
- **MPI_reduction_operation** : type d'opération à effectuer pour la réduction (ex : **MPI_SUM**)



https://www.open-mpi.org/doc/v1.5/man3/MPI_Allreduce.3.php

Exercice n°5 : Utilisation de la communication collective MPI_REDUCE



- Rendez vous dans le dossier de l'exercice n°5 appelé `5_reduce_com`



```
> cd exercises/mpi/5_reduce_com
```

- Ouvrez les instructions contenues dans le fichier `README.md` avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

Communication bloquante : ouverture



D'autres variantes de communications collectives sont à découvrir dans le cours de l'IDRIS et la documentation MPI

Communications collectives MPI

A ce stade du cours, vous savez maintenant :

- Effectuer des communications collectives
- Effectuer des réductions

II. Introduction au parallélisme par échange de message via MPI

5) Topologie cartésienne

Décomposition de domaine cartésienne

En calcul scientifique, il est courant de **décomposer le domaine d'étude** (grille, matrice) **en sous-domaines**, chaque sous-domaine étant alors **géré par un processus MPI unique**.


Sur **grille régulière et structurée**, une approche simple et classique consiste à diviser le domaine en blocs réguliers possédant alors dans sa **mémoire locale** une **partie unique de la grille globale**.

- Méthode de décomposition **cartésienne**



Il s'agit d'un exemple typique de parallélisme de donnée


Décomposition de domaine cartésienne



Décomposition de domaine cartésienne : coordonnées

Une **topologie** cartésienne a besoin de :

- **Coordonnées** pour situer les processus (bloc) dans l'espace cartésien
- De **rangs** pour chaque processus en adéquation avec la topologie cartésienne
- exemple : le rang 5 a pour coordonnées (1,1)



Décomposition de domaine cartésienne : création



Deux solutions pour mettre en place une topologie cartésienne :

- Le faire à la main
- Faire appel aux fonctions MPI conçues pour ça

Décomposition de domaine cartésienne : création via `MPI_CART_CREATE`

`MPI_CART_CREATE` permet de définir une topologie cartésienne à partir d'un ancien communicateur (celui par défaut par exemple `MPI_COMM_WORLD`)



.f90

```
MPI_CART_CREATE(old_communicator, dimension,  
                ranks_per_direction, periodicity,  
                reorganisation, cartesian_communicator, ierror)
```

- `old_communicator` : ancien communicateur (`MPI_COMM_WORLD` par exemple)
- `dimension` (entier) : dimension de la topologie (2 pour 2D par exemple)
- `ranks_per_direction` (tableau d'entier) : le nombre de rangs dans chaque dimension
- `Periodicity` (tableau de booléens) : permet de définir les directions périodiques (true)
- `Reorganisation` (booléen) : réorganisation des rangs pour optimiser les échanges (true)
- `cartesian_communicator` (entier) : nouveau communicateur renvoyé par la fonction qui vient remplacer l'ancien communicateur.



https://www.open-mpi.org/doc/v2.0/man3/MPI_Cart_create.3.php

Décomposition de domaine cartésienne : création



Comme pour n'importe quel communicateur, on peut récupérer les rangs dans le communicateur cartésien (`cartesian_communicator`) avec `MPI_COMM_RANK`

Décomposition de domaine cartésienne : récupérer les coordonnées d'un rang via `MPI_CART_COORDS`

- `MPI_CART_COORDS` permet de récupérer les coordonnées d'un rang donné dans la topologie cartésienne.



.f90

```
CALL MPI_CART_COORDS(cartesian_communicator, rank, dimension, &  
rank_coordinates, ierror)
```

- `Dimension` (entier) : dimension de la topologie (2 pour 2D par exemple)
- `ranks_coordinates` (tableau d'entier) : les coordonnées du rang `rank` dans `cartesian_communicator`



https://www.open-mpi.org/doc/v2.0/man3/MPI_Cart_coords.3.php

Décomposition de domaine cartésienne : les voisins

- Chaque processus doit être en mesure de récupérer **le rang de ses voisins** dans la topologie cartésienne pour d'éventuelles communications.



Décomposition de domaine cartésienne : récupérer les rangs des voisins via `MPI_CART_SHIFT`

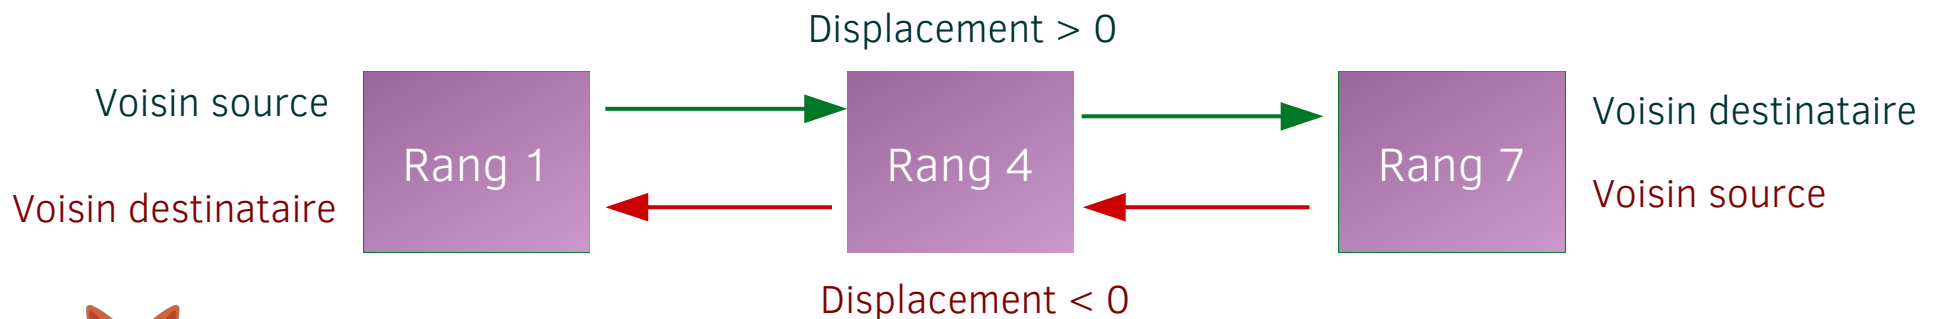
`MPI_CART_SHIFT` permet de récupérer les rangs voisins d'un rang donné



.f90


```
MPI_CART_SHIFT(cartesian_communicator, direction,  
displacement,  
rank_neighbors_src, rank_neighbors_dest, ierror)
```

- **direction** (entier) : 1 pour la première coordonnée, 2 pour la deuxième coordonnée
- **Displacement** (entier) : pas de déplacement dans la direction souhaitée, si > 0 déplacement vers les coordonnées supérieures, si < 0 vers les coordonnées inférieures
- **rank_neighbord_source** : si $\text{displacement} > 0$, correspond au voisin source
- **rank_neighbord_dest** : si $\text{displacement} > 0$, correspond au voisin destinataire



https://www.open-mpi.org/doc/v2.0/man3/MPI_Cart_shift.3.php

Exemple de topologie cartésienne 2D



Exemple de topologie cartésienne 2D



.f90

```
Integer, dimension(2) :: ranks_per_direction = (/4, 3/)
Logical, dimension(2) :: periodicity = (/ .true., .true. /)
Logical                :: reorganisation = .true.
Integer                :: cartesian_communicator
Integer, dimension(2) :: rank_coordinates
Integer                :: rank_neighbors_mx, rank_neighbors_px
Integer                :: rank_neighbors_my, rank_neighbors_py

Call MPI_INIT(ierr)

Call MPI_CART_CREATE(MPI_COMM_WORLD, 2, ranks_per_direction, periodicity,
                    reorganisation, cartesian_communicator, ierr)

Call MPI_COMM_RANK(cartesian_communicator, rank, ierr)

Call MPI_CART_COORDS(cartesian_communicator, rank, 2, rank_coordinates, ierr)

CALL MPI_CART_SHIFT(cartesian_communicator, 1, 1, &
                   rank_neighbors_my, rank_neighbors_py, ierr)

CALL MPI_CART_SHIFT(cartesian_communicator, 0, 1, &
                   rank_neighbors_mx, rank_neighbors_px, ierr)
```

Exercice n°6 : Création d'une topologie cartésienne



- Rendez vous dans le dossier de l'exercice n°6 appelé `6_cartesian_com`



```
> cd exercises/mpi/6_cartesian_com
```

- Ouvrez les instructions contenues dans le fichier `README.md` avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

Décomposition de domaine cartésienne

A ce stade du cours, vous savez maintenant :

- Créer un communicateur cartésien pour décomposer vos données
- Utiliser les fonctions liées à la décomposition cartésienne