Introduction au parallélisme par échange de message via MPI

Master DFE – année 2020/2021

Mathieu Lobet, Maison de la Simulation Mathieu.lobet@cea.fr

Introduction au parallélisme par échange de message via MPI

1) Description de l'approche

Cours et matériel supplémentaires sur internet



Selon moi, le cours le plus complet sur MPI en français et anglais: http://www.idris.fr/formations/mpi/

Les implémentations fournissent en général une documentation en ligne complète :

https://www.open-mpi.org/

https://www.mcs.anl.gov/research/projects/mpi/learning.html

http://mpi.deino.net/

Information concernant le cours



Il existe des implémentations de MPI pour Fortran95, Fortran08, C, C++ et python.

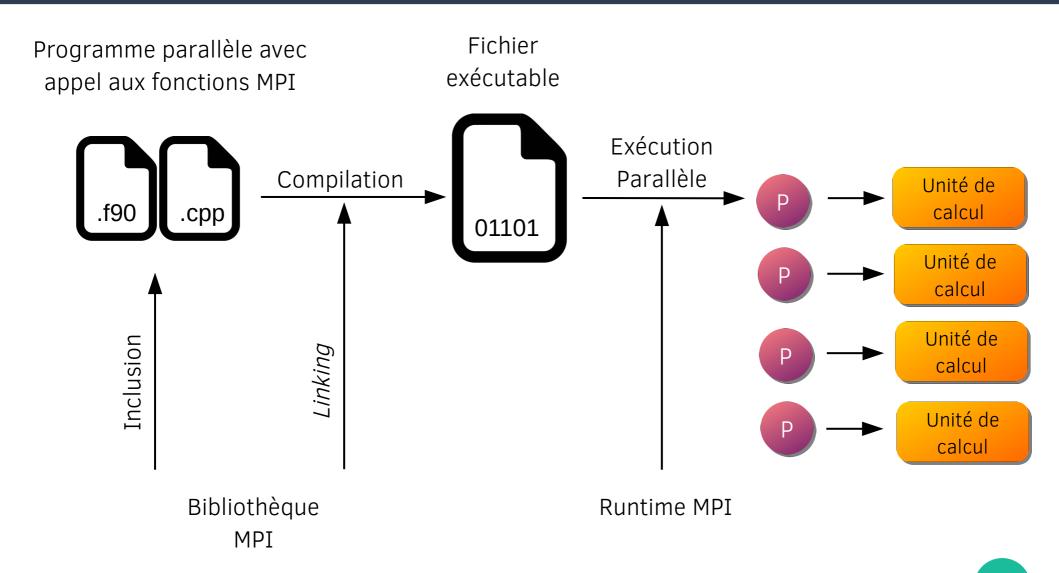
La syntaxe diffère pour chaque langage. Le cours s'axe sur la version Fortran95 et C.

On programmera en C++ en utilisant l'API C.

Il existe également une version C++ avec classe pour les communicateurs ainsi qu'une version adaptée au Fortran moderne.

La philosophie reste la même peut importe le langage choisi.

La chaîne de compilation et d'exécution d'un programme MPI



Implémentations MPI



Implémentations libres que vous pouvez vous procurer pour vos ordinateurs :

- OpenMPI
- MPICH
- Deino (Windows)

Implémentation propriétaire :

• IntelMPI

Disponible en Fortran, C, C++, Python



L'installation peut se faire par les sources ou via apt-get install

Compilation d'un programme MPI (Fortran)

La compilation fait appel au wrapper MPI mpif90. Le wrapper utilise le compilateur Fortran par défaut (par exemple gfortran) en y ajoutant des options de compilation supplémentaires et les chemins vers la bibliothèque MPI.

Pour connaître le contenu du wrapper :



> mpif90 -show

Pour compiler:



> mpif90 program.f90 -o executable

Compilation d'un programme MPI (C++)

La compilation fait appel au wrapper MPI mpic++. Le wrapper utilise le compilateur C++ par défaut (par exemple g++) en y ajoutant des options de compilation supplémentaires et les chemins vers la bibliothèque MPI.

Pour connaître le contenu du wrapper :



Pour compiler:



> mpiC++ program.cpp -o executable

Exécution d'un programme MPI

- L'exécution se fait par l'intermédiaire de la commande mpirun.
- -np représente le nombre de processus MPI à lancer.
- Si le nombre de processus MPI est inférieur au nombre d'unités de calcul disponible, chaque processus est exécuté par une unité indépendante
- Il est possible de lancer plus de processus MPI que d'unités de calcul, dans ce cas, les ressources sont partagées.

Pour exécuter votre code en ligne de commande :



> mpirun -np 6 ./executable

Démarrage d'un programme MPI : notion de communicateur

- Un communicateur est un ensemble de processus MPI capable de communiquer entre eux.
- Au sein d'un communicateur, chaque processus MPI est représenté par un rang (rank) unique sous forme d'un entier.
- Le communicateur par défaut regroupe l'ensemble des processus et se nomme MPI_COMM_WORLD.



MPI_COMM_WORLD : Communicateur composé de 4 rangs

Démarrage d'un programme MPI (Fortran) : inclure MPI

La première étape consiste à ne pas oublier d'inclure le module MPI (header en C/C++)



```
Program test

Use mpi

...

End program
```



```
#include <mpi.h>
int main( int argc, char *argv[] )
{
}
```

Démarrage d'un programme MPI (Fortran) : initialiser et finaliser MPI

- MPI est une bibliothèque qui fonctionne par appel à des fonctions (subroutine en Fortran)
- La deuxième étape importante est l'initialisation de MPI
- Il ne faut pas oublier de finaliser pour finir son programme proprement



```
Program test
Use mpi
Implicit none
Integer :: ierror

Call MPI_INIT(ierror)
...
Call MPI_FINALIZE(ierror)
End program
```

Démarrage d'un programme MPI (C++) : initialiser et finaliser MPI

- MPI est une bibliothèque qui fonctionne par appel à des fonctions (subroutine en Fortran)
- La deuxième étape importante est l'initialisation de MPI
- Il ne faut pas oublier de finaliser pour finir son programme proprement



```
#include <mpi.h>
int main( int argc, char *argv[] )
{
   int ierror ;
   ierror = MPI_Init() ;
   ...
   ierror = MPI_Finalize() ;
}
```

Démarrage d'un programme MPI : initialiser MPI

- L'initialisation se fait avec la fonction MPI_INIT.
- Toute fonction MPI renvoie en dernier argument un code d'erreur noté ici ierror.

```
.f90

Ierror = MPI_INIT();

.cpp
```

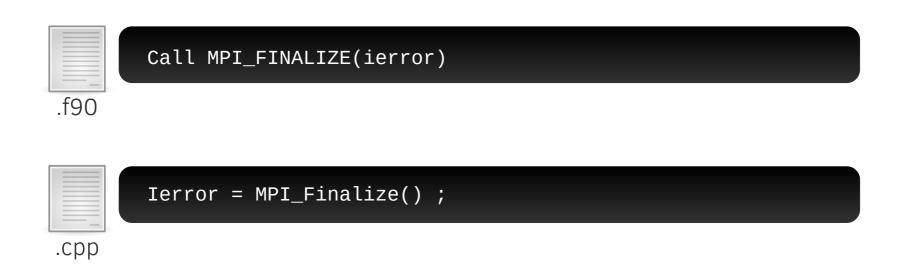
Le code d'erreur permet si besoin de vérifier qu'un appel s'est bien déroulé



https://www.open-mpi.org/doc/v1.8/man3/MPI_Init.3.php

Démarrage d'un programme MPI (Fortran) : finaliser MPI

- La finalisation se fait avec la fonction MPI_FINALIZE.
- Elle est appelée à la toute fin du programme



Démarrage d'un programme MPI (Fortran) : récupérer le nombre de rangs

• Le nombre de rangs dans le communicateur MPI_COMM_WORLD se récupère via la fonction MPI_COMM_SIZE : c'est le nombre total de processus demandé.

```
Integer :: number_of_ranks

call MPI_COMM_SIZE(MPI_COMM_WORLD, number_of_ranks, ierror)

Int number_of_ranks ;

cpp

Ierror = MPI_Comm_size(MPI_COMM_WORLD, &number_of_ranks) ;
```

- MPI_COMM_WORLD : communicateur (ici celui par défaut)
- Number_of_ranks : entier renvoyé contenant le nombre de rangs MPI



https://www.open-mpi.org/doc/current/man3/MPI_Comm_size.3.php

Démarrage d'un programme MPI (Fortran) : récupérer le rang de chaque processus MPI

 Chaque processus récupère son rang dans le communicateur MPI_COMM_WORLD via la fonction MPI_COMM_RANK.

```
Integer :: rank
Call MPI_COMM_RANK(MPI_COMM_WORLD, rank, ierror)

int rank;
Ierror = MPI_Comm_rank(MPI_COMM_WORLD, &rank);
```

- MPI_COMM_WORLD : communicateur (ici celui par défaut)
- rank : entier renvoyé désignant le rang du processus qui appelle la fonction



https://www.open-mpi.org/doc/v3.0/man3/MPI_Comm_rank.3.php

Mesure du temps : MPI_WTIME (fortran)

• MPI_WTIME permet de récupérer le temps écoulé sur le processus courant en seconde

```
Real :: time
Time = MPI_WTIME()
```

 Par deux appels et une soustraction, cette fonction permet de déterminer le temps passer dans une section du code

```
Real :: time
time = MPI_WTIME()

! Des calculs...
...
! Ce temps est le temps passé entre les deux appels à MPI_WTIME
time = MPI_WTIME() - time
```

https://www.open-mpi.org/doc/v4.0/man3/MPI_Wtime.3.php

Mesure du temps : MPI_Wtime (C++)

MPI_Wtime permet de récupérer le temps écoulé sur le processus courant en seconde

```
double time ;
        Time = MPI_Wtime() ;
.cpp
```

 Par deux appels et une soustraction, cette fonction permet de déterminer le temps passer dans une section du code

.cpp

```
double time ;
                     time = MPI_Wtime() ;
                        ! Des calculs...
! Ce temps est le temps passé entre les deux appels à MPI_Wtime
                  time = MPI_Wtime() - time ;
```



https://www.open-mpi.org/doc/v4.0/man3/MPI_Wtime.3.php

Exercice n°1 : votre premier programme MPI



- Rendez vous sur le Gitlab des exercices : https://gitlab.maisondelasimulation.fr/mlobet/cours-hpc-m2-dfe
- Télécharger les exercices sur votre session de travail
- Décompressez l'archive en ligne de commande



- > tar xvf archivedossier.tar
- Rendez vous dans le dossier de l'exercice n°1 appelé 1_initialization



- > cd exercises/mpi/1_initialization
- Ouvrez les instructions contenues dans le fichier README.md avec votre éditeur de fichier favori (vim, emacs, atom, gedit...)



Vous pouvez lire le README directement depuis le Gitlab et c'est plus confortable comme ça.

Différencier du code pour des processus donnés



Le programme s'exécute simultanément autant de fois qu'il y a de processus parallèle : chaque ligne de code est appelée par chaque processus.

Pour faire en sorte que certaines portions de code soient réservées à certains processus, on utilise des conditions **if** avec le numéro de rang comme condition.



.f90

```
If (rank == 1) then
 ! Cette portion de code ne sera exécutée que par le rang 1
    ...
End if
```



.cpp

```
if (rank == 1) {
  ! Cette portion de code ne sera exécutée que par le rang 1
  ...
}
```

Votre premier programme MPI

A ce stade du cours, vous savez maintenant :

- Écrire un programme parallèle simple
- Compiler un programme MPI
- Exécuter un programme MPI
- Récupérer le nombre de rangs et le rang de chaque processus

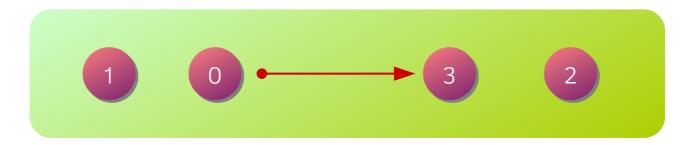
Introduction au parallélisme par échange de message via MPI

2) Les communications point à point bloquantes

Notion de communication point à point

Point to point communication

- L'échange de message constitue la base du concept MPI
- L'échange de message se décompose toujours en deux étapes :
 - Envoi : Un processus envoie un message à un processus destinataire en spécifiant le rang
 - Réception : Un processus doit explicitement recevoir le message en connaissant le rang de l'expéditeur



- Le processus de rang 0 envoie un message au processus de rang 3
- Le processus de rang 3 reçoit un message du processus de rang 0

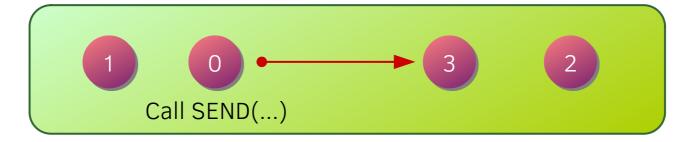
Notion de communication point à point : Envoi de données via MPI_SEND

Point to point communication : MPI_SEND

MPI_SEND est la fonction appelée par le processus expéditeur



MPI_SEND(message, size, data_type, destination_rank, tag, communicator, ierror)





https://www.open-mpi.org/doc/v1.8/man3/MPI_Send.3.php

Notion de communication point à point : Envoi de données via MPI_SEND (Fortran)

Point to point communication : SEND

MPI_SEND est la fonction appelée par le processus expéditeur



MPI_SEND(message, size, data_type, destination_rank, tag, communicator, ierror)

- Message : la variable contenant le message à envoyer (booléen, entier, double, caractère, chaîne, tableau, structure plus complexe...)
- Size : nombre d'éléments constituant le message (> 1 uniquement pour une chaîne ou un tableau)
- data_type: type de variable utilisée pour le message (MPI_INTEGER pour les integer, MPI_DOUBLE_PRECISION pour les real(8), MPI_REAL pour les real(4)...)
- Tag: numéro attribué à la communication si plusieurs coms vers le même processus
- destination_rank : rang du processus destinataire



https://linux.die.net/man/3/mpi_real

Notion de communication point à point : Envoi de données via MPI_Send (C/C++)

Point to point communication : MPI_Send

MPI_Send est la fonction appelée par le processus expéditeur



MPI_Send(message, size, data_type, destination_rank, tag, communicator)

- Message (const void *) : la variable contenant le message à envoyer (booléen, entier, double, caractère, chaîne, tableau, structure plus complexe...)
- Size (int): nombre d'éléments constituant le message (> 1 uniquement pour une chaîne ou un tableau)
- data_type: type de variable utilisée pour le message (MPI_INT pour les integer, MPI_DOUBLE pour les double, MPI_FLOAT pour les float...)
- Tag (int): numéro attribué à la communication si plusieurs coms vers le même processus
- destination_rank (int) : rang du processus destinataire



https://www.open-mpi.org/doc/v1.8/man3/MPI_Send.3.php

Exemple d'utilisation de MPI_SEND

Point to point communication : MPI_SEND

Envoi d'un message de type real(8) au processus de rang 3 par le processus de rang 2





.cpp

Exemple d'utilisation de MPI_SEND

Point to point communication : MPI_SEND

 Envoi d'un message de type tableau contenant 5 entiers au processus de rang 6 par le processus de rang 1





.cpp

Exemple d'utilisation de MPI_SEND

Point to point communication : MPI_SEND

• Envoi d'un message au processus de rang 6 par le processus de rang 1 de type chaîne de caractère contenant 4 caractères et commençant au deuxième élément du message





.cpp

```
char message[10] = « abcdefghij » ;
int tag, ierror ;

if (rank == 1) {
   ! Seulement « bcde » est envoyé
   Ierror = MPI_Send(&message[1], 4, MPI_CHAR, 6, tag, MPI_COMM_WORLD) ;
}
```

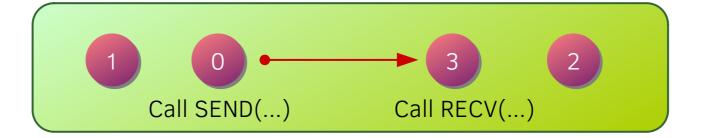
Notion de communication point à point : Réception de données via MPI_RECV

Point to point communication : MPI_RECV

MPI_RECV est la fonction appelée par le processus destinataire



MPI_RECV(message, size, data_type, source_rank, tag, communicator, status, ierror)





https://www.open-mpi.org/doc/v1.8/man3/MPI_Recv.3.php

Notion de communication point à point : Réception de données via MPI_RECV (Fortran)

Point to point communication : MPI_RECV

MPI_RECV est la fonction appelée par le processus destinataire



MPI_RECV(message, size, data_type, source_rank, tag, communicator, status, ierror)

- Message : la variable contenant le message à recevoir (booléen, entier, double, caractère, chaîne, tableau, structure plus complexe...)
- Size : nombre d'éléments constituant le message (> 1 uniquement pour une chaîne ou un tableau)
- data_type: type de variable utilisée pour le message (MPI_INTEGER pour les integer, MPI_DOUBLE_PRECISION pour les real(8), MPI_REAL pour les real(4)...)
- source_rank : rang du processus expéditeur
- Status : état de la communication (en dehors de la portée de ce cours)

Notion de communication point à point : Réception de données via MPI_Recv (C/C++)

Point to point communication : MPI_Recv

RECV est la fonction appelée par le processus destinataire



MPI_Recv(message, size, data_type, source_rank, tag, communicator, status, ierror)

- Message (void *) : la variable contenant le message à recevoir (booléen, entier, double, caractère, chaîne, tableau, structure plus complexe...)
- Size (int): nombre d'éléments constituant le message (> 1 uniquement pour une chaîne ou un tableau)
- data_type (MPI_Datatype) : type de variable utilisée pour le message (MPI_INT pour les int, MPI_DOUBLE pour les double, MPI_FLOAT pour les float...)
- source_rank (int): rang du processus expéditeur
- Status (MPI_Status *) : état de la communication (en dehors de la portée de ce cours)



https://www.open-mpi.org/doc/v1.8/man3/MPI_Recv.3.php

Exemple d'utilisation de MPI_SEND and MPI_RECV (Fortran95)

Point to point communication : MPI_SEND and MPI_RECV

- Envoi d'un message de type real(8) au processus de rang 3 par le processus de rang 2
- Réception d'un message de type real(8) par le rang 2 venant du rang 3



```
Real(8) :: message
Integer :: tag
Integer :: ierror
If (rank == 2) then
  Message = 1245.76
  Call MPI_SEND(message, 1, MPI_DOUBLE_PRECISION, 3, tag, &
                MPI_COMM_WORLD, ierror)
End if
If (rank == 3) then
  Call MPI_RECV(message, 1, MPI_DOUBLE_PRECISION, 2, tag, &
                MPI_COMM_WORLD, MPI_STATUS_IGNORE, ierror)
End if
```

Exemple d'utilisation de MPI_Send and MPI_Recv (C/C++)

Point to point communication : MPI_Send and MPI_Recv

- Envoi d'un message de type double au processus de rang 3 par le processus de rang 2
- Réception d'un message de type double par le rang 2 venant du rang 3

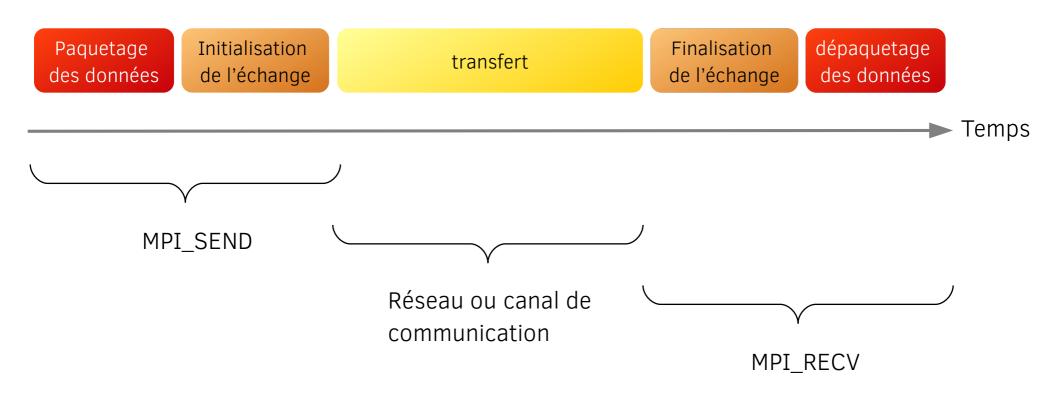


.cpp

Mieux comprendre une communication

Point to point communication : SEND and RECV

• Une communication se compose d'un ensemble de sous-étapes :



Exercice n°2: Utilisation des communications point à point



Rendez vous dans le dossier de l'exercice n°2 appelé 2_blocking_com



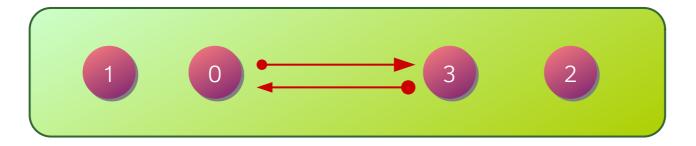
> cd exercises/mpi/2_blocking_com

• Ouvrez les instructions contenues dans le fichier README.md avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

Communication point à point : MPI_SENDRECV

Point to point communication

• Il est parfois nécessaire de faire un échange mutuel de données. Pour ce faire, il existe une fonction qui allie l'envoie et la réception : MPI_SENDRECV.



Le processus de rang 0 envoie et reçoit un message au processus de rang 3 Le processus de rang 3 envoie et reçoit un message du processus de rang 0

Communication point à point : MPI_SENDRECV (Fortran95)

Point to point communication : MPI_SENDRECV

SENDRECV est appelée par les processus expéditeur et destinataire en même temps



```
MPI_SENDRECV(
send_message, send_size, send_type, destination, send_tag, &
recv_message, recv_size, recv_type, source, recv_tag, &
communicator, status, ierror)
```





https://www.open-mpi.org/doc/v1.8/man3/MPI_Sendrecv.3.php

Communication point à point : MPI_Sendrecv (C/C++)

Point to point communication : MPI_Sendrecv

MPI_Sendrecv est appelée par les processus expéditeur et destinataire en même temps

```
.cpp
```

```
ierror = MPI_Sendrecv(
send_message, send_size, send_type, destination, send_tag,
recv_message, recv_size, recv_type, source, recv_tag,
communicator, status);
```

- send_message (const void *) : données envoyées
- recv_message (void *) : données reçues
- Les autres paramètres sont les mêmes que pour MPI_Send et MPI_Recv



https://www.open-mpi.org/doc/v1.8/man3/MPI_Sendrecv.3.php

Exemple d'utilisation de MPI_SENDRECV (Fortran 95)

Point to point communication : MPI_SENDRECV

- Envoi et réception d'un message de type real(8) au processus de rang 3 par le processus de rang 2
- Envoi et réception d'un message de type real(8) par le rang 2 venant du rang 3



.f90

```
Real(8) :: send_message
Real(8) :: recv message
Integer :: send_tag
Integer :: recv_tag
Integer :: ierror
If (rank == 2) then
  send_message = 1245.76
  Call MPI_SENDRECV(send_message, 1, MPI_DOUBLE_PRECISION, 3, send_tag, &
                   recv_message, 1, MPI_DOUBLE_PRECISION, 3, recv_tag, &
                   MPI_COMM_WORLD, MPI_STATUS_IGNORE, ierror)
End if
If (rank == 3) then
  send_message = 4567.32
                   recv message, 1, MPI DOUBLE PRECISION, 2, recv tag, &
                   MPI COMM WORLD, MPI STATUS IGNORE, ierror)
End if
```

Exemple d'utilisation de MPI_Sendrecv

Point to point communication : MPI_Sendrecv

- Envoi et réception d'un message de type **double** au processus de rang 3 par le processus de rang 2
- Envoi et réception d'un message de type double par le rang 2 venant du rang 3



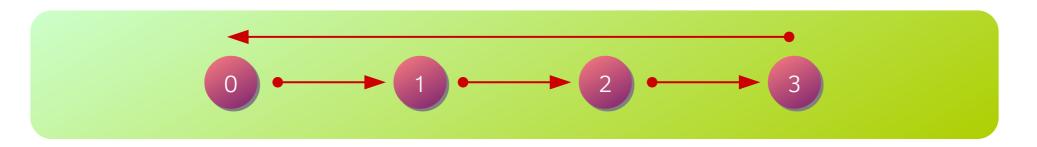
.cpp

```
double send_message, recv_message;
int send_tag, recv_tag, ierror ;
if (rank == 2) {
  send_message = 1245.76;
  ierror = MPI_Sendrecv(&send_message, 1, MPI_DOUBLE, 3, send_tag,
                   &recv_message, 1, MPI_DOUBLE, 3, recv_tag,
                   MPI COMM WORLD, MPI STATUS IGNORE);
If (rank == 3) {
  send_message = 4567.32;
                   MPI COMM WORLD, MPI STATUS IGNORE);
```

Communication point à point : MPI_SENDRECV pour les communications chaînées

Point to point communication

- La fonction MPI_SENDRECV est également nécessaire pour effectuer des communications chaînées
- L'utilisation de MPI_SEND et MPI_RECV nécessiterait de gérer manuellement les synchronisations



Chaque processus reçoit un élément d'un processus A et envoie des données à un processus B distinct.

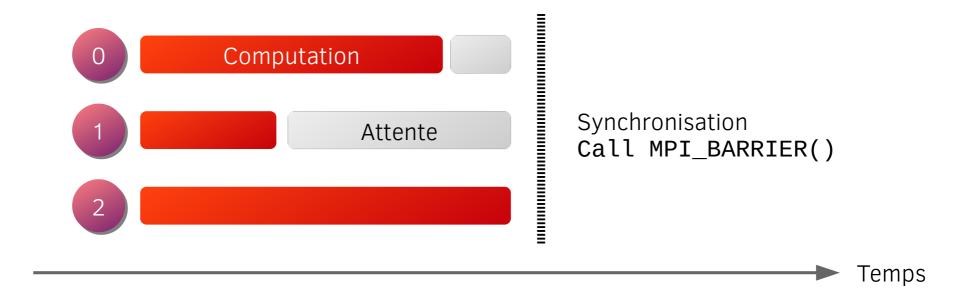


Lorsqu'une communication n'arrive pas à son terme, le programme attend et peut rester figé.

Notion de barrière explicite

Explicit barrier

- Il est parfois nécessaire d'imposer un une étape de synchronisation ou barrière qui ne sera pas franchie tant que tous les processus ne seront pas arrivés à ce niveau
- La fonction MPI_BARRIER est une manière explicite d'exiger cette synchronisation dans le code





https://www.open-mpi.org/doc/v1.5/man3/MPI_Barrier.3.php

Notion de barrière implicite

Implicit barrier

- Certaines fonctions d'échange induisent des barrières implicites au niveau des processus concernés
- C'est le cas de MPI_SEND, MPI_RECV, MPI_SENDRECV d'où l'appellation de communication bloquante





Si certains processus sont en avance, ils effectuent une attente active ou passive. Cette attente est vue comme une perte de ressource.

Exercice n°3 : Chaîne ou anneau de communication

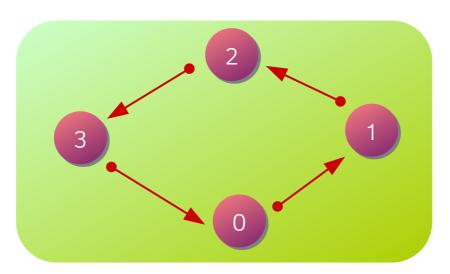


Rendez vous dans le dossier de l'exercice n°3 appelé 3_sendrecv



> cd exercises/mpi/3_sendrecv

• Ouvrez les instructions contenues dans le fichier README.md avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.



Anneau de communication

Premiers échanges MPI

A ce stade du cours, vous savez maintenant :

- Faire communiquer différents processus entre eux
- Gérer des chaînes de communication
- Demander une synchronisation explicite

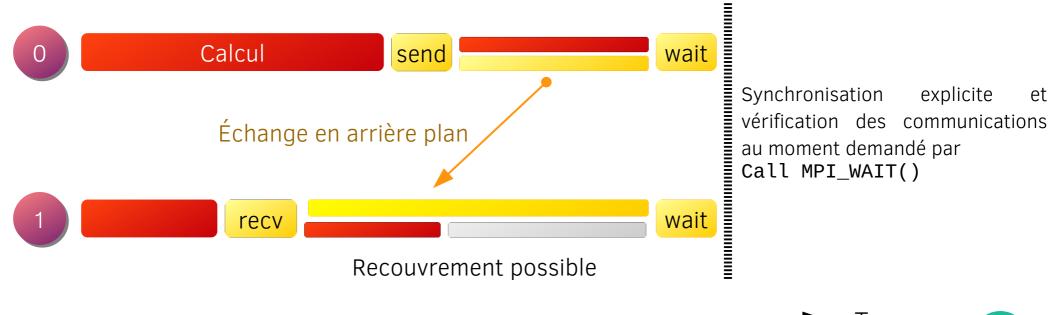
Introduction au parallélisme par échange de message via MPI

3) Les communications point à point nonbloquantes

Communication point à point non-bloquante

Non-blocking communication

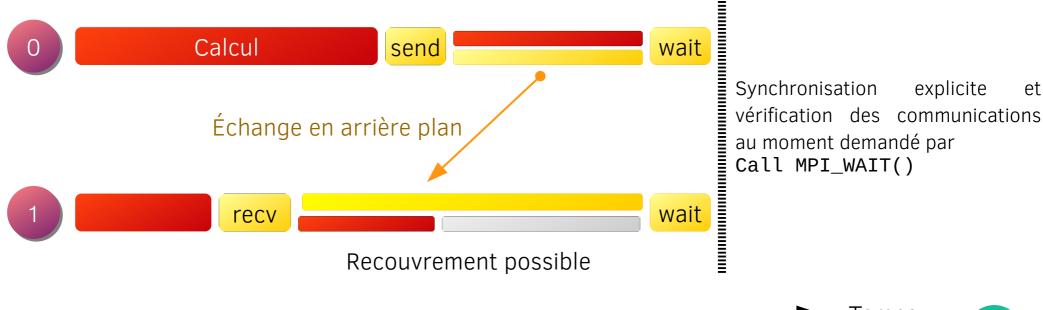
- Les communications non-bloquantes permettent d'éviter la synchronisation implicite des processus.
- Une synchronisation explicite est nécessaire pour s'assurer que les communications ont eu lieu avant d'utiliser les données échangées
- Ce type de communication permet de recouvrir communication et calcul: envoi et réception en arrière plan



Communication point à point non-bloquante

Non-blocking communication

- Les communications se font via les fonctions MPI_ISEND et MPI_IRECV.
- Les communications se voient attribuées un identifiant unique
- A un moment donné, il est nécessaire de vérifier que ces communications ont eu lieu, c'est le rôle de MPI_WAIT. Cette fonction analyse les identifiants fournis.
- MPI_WAIT impose une barrière



Les fonctions MPI Isend et MPI Irecv (Fortran95)

MPI Isend and MPI Irecv

MPI_ISEND est la fonction appelée par le processus expéditeur



MPI_ISEND(message, size, data_type, destination_rank, tag, communicator, request, ierror)

MPI_IRECV est la fonction appelée par le processus receveur



MPI_IRECV(message, size, data_type, source_rank, tag, communicator, request, ierror)

f90

- Les paramètres sont les mêmes pour que pour les communications bloquantes.
- S'ajoute la variable request (int) utilisée par MPI_WAIT pour vérifier l'état de la communication



https://www.open-mpi.org/doc/v4.0/man3/MPI_Isend.3.php https://www.open-mpi.org/doc/v4.0/man3/MPI_Irecv.3.php

Les fonctions MPI_Isend et MPI_Irecv (C/C++)

MPI_Isend and MPI_Irecv

MPI_Isend est la fonction appelée par le processus expéditeur

```
.cpp
```

```
MPI_Isend(&message, size, data_type, destination_rank, tag,
communicator, request);
```

MPI_Irecv est la fonction appelée par le processus receveur

```
.cpp
```

```
MPI_Irecv(&message, size, data_type, source_rank, tag, communicator, request);
```

- Les paramètres sont les mêmes pour que pour les communications bloquantes.
- S'ajoute la variable request (de type MPI_Request *) utilisé par MPI_WAIT pour vérifier l'état de la communication



https://www.open-mpi.org/doc/v4.0/man3/MPI_Isend.3.php https://www.open-mpi.org/doc/v4.0/man3/MPI_Irecv.3.php

La fonction MPI_Wait MPI_Wait

 MPI_Wait est la fonction appelée pour vérifier et attendre que la communication a bien été effectuée

```
MPI_WAIT(request, status, ierror)

.f90

MPI_Wait(request, status);
.cpp
```



Exemple d'utilisation des communications non-bloquantes (Fortran 95)

Non-blocking communication

- Envoi d'un message de type real(8) au processus de rang 3 par le processus de rang 2
- Réception d'un message de type real(8) par le rang 2 venant du rang 3



```
Real(8) :: send_message, recv_message
Integer :: send_tag, recv_tag, ierror
Integer :: request
If (rank == 2) then
  send message = 1245.76
  Call MPI_ISEND(send_message, 1, MPI_DOUBLE_PRECISION, 3, send_tag, &
                   MPI COMM WORLD, request, ierror)
End if
If (rank == 3) then
  Call MPI_IRECV(recv_message, 1, MPI_DOUBLE_PRECISION, 2, recv_tag, &
                   MPI_COMM_WORLD, request, ierror)
End if
Call MPI_WAIT(request, MPI_COMM_WORLD, ierror) ;
```

Exemple d'utilisation des communications non-bloquantes (C/C++)Non-blocking communication

- Envoi d'un message de type double au processus de rang 3 par le processus de rang 2
- Réception d'un message de type double par le rang 2 venant du rang 3



.cpp

```
double send_message, recv_message ;
int send_tag, recv_tag, ierror;
MPI_Request request ;
If (rank == 2) {
  send_message = 1245.76
  Call MPI_Isend(send_message, 1, MPI_DOUBLE, 3, send_tag, &
                   MPI COMM WORLD, request);
}
If (rank == 3) {
                   MPI_COMM_WORLD, request) ;
}
MPI_Wait(request, MPI_COMM_WORLD) ;
```

La fonction MPI_WAITALL MPI Wait

• MPI_WAITALL effectue l'action de MPI_WAIT sur un tableau de requêtes.

```
MPI_WAITALL(number_of_request, request, status, ierror)
.f90

MPI_Waitall(number_of_request, request, status);
.cpp
```

 request et status sont alors des tableaux (d'entiers en Fortran95, MPI_Request et MPI_Status * en C)



https://www.open-mpi.org/doc/v4.0/man3/MPI_Waitall.3.php

Mélange des types de communication



Il est tout à fait possible de mélanger des appels bloquants à des appels non-bloquants.

Exercice n°4: Utilisation des communications non bloquantes



Rendez vous dans le dossier de l'exercice n°4 appelé 4_nonblocking_com



> cd exercises/mpi/4_nonblocking_com

• Ouvrez les instructions contenues dans le fichier README.md avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

Introduction au parallélisme par échange de message via MPI

4) Les communications collectives

Communication collective : les différents types

Collective communication

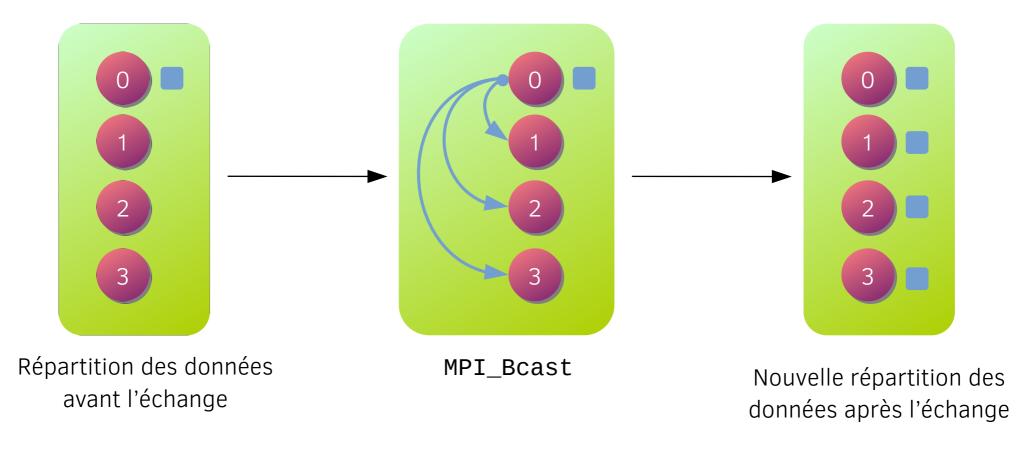
- Les communications collectives sont des communications qui font intervenir plusieurs processus (voir tout le communicateur) dans le but de propager ou de rassembler de l'information.
- 3 types de communication collective :
 - Synchronisation : c'est le MPI_BARRIER
 - Transfert de données (diffusion, collecte)
 - Transfert et opérations sur les données (opération de réduction)



Les versions standards induisent des barrières implicites pour les processus concernés. Pour chaque processus, la barrière est relâchée dès la participation terminée.

Communication collective : diffusion générale grâce à MPI_Bcast

• Envoi d'une donnée depuis un processus vers tous les processus du communicateur

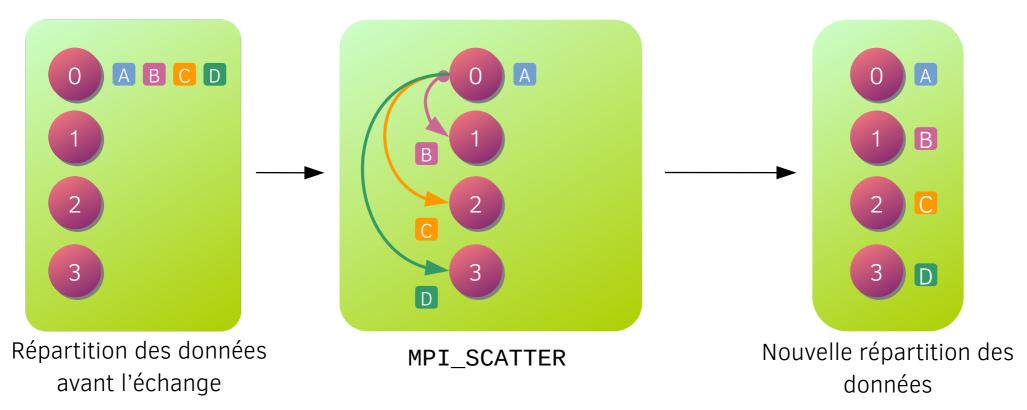




https://www.open-mpi.org/doc/v4.0/man3/MPI_Bcast.3.php

Communication collective : diffusion sélective grâce à MPI_Scatter Collective communication

 Partage de données sélectif (selon les critères du développeur) depuis un processus vers tous les processus du communicateur

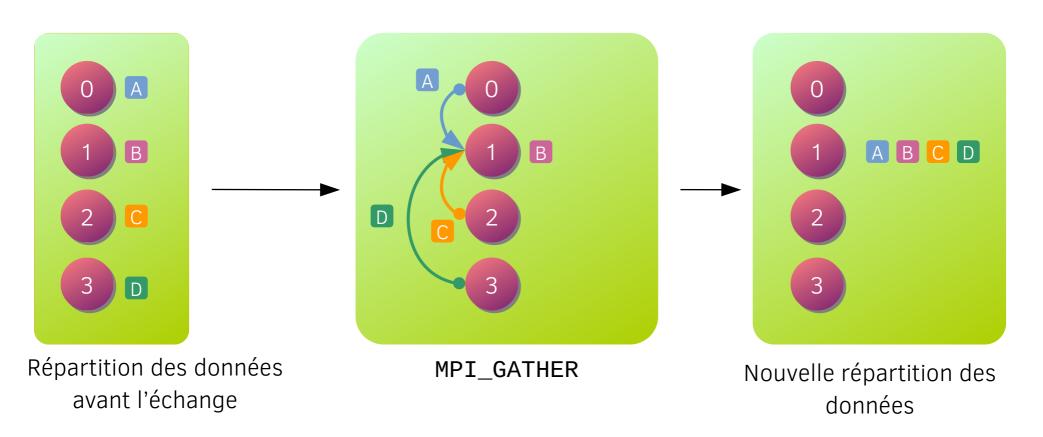




https://www.open-mpi.org/doc/v4.0/man3/MPI_Scatter.3.php

Communication collective : collecte grâce à MPI_Gather Collective communication

• Envoi de données réparties sur plusieurs processus vers un processus unique

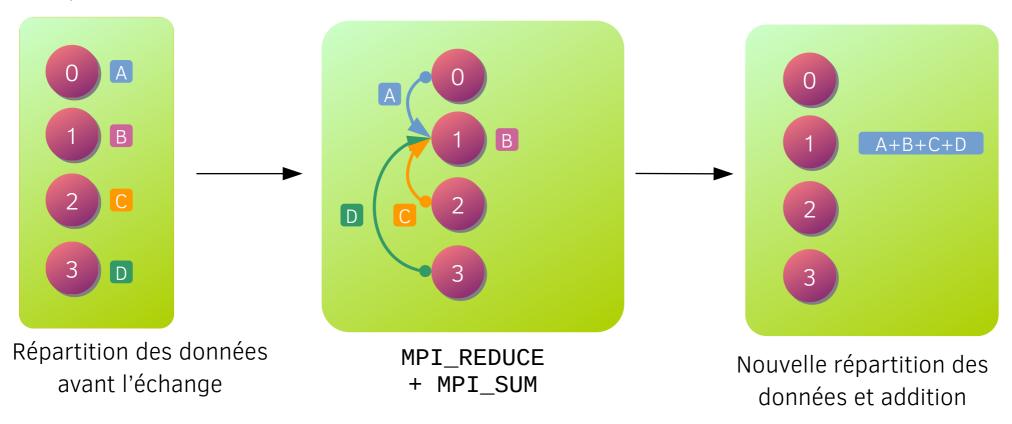




Communication collective : réduction grâce à MPI_Reduce

Collective communication

• Envoi de données réparties sur plusieurs processus vers un seul processus avec une opération de réduction réalisée simultanément





https://www.open-mpi.org/doc/v4.0/man3/MPI Reduce.3.php

Communication collective: réduction grâce à MPI_Reduce (Fortran95)

Collective communication

MPI_Reduce est appelée par les processus expéditeurs et destinataires en même temps



MPI_REDUCE(send_value, recv_value, size, MPI_data_type,
MPI_reduction_operation, destination, communicator, ierror)

- send_value: la valeur à envoyer par chaque processus
- recv_value : la valeur reçue suite aux échanges et à la réduction par le destinataire seulement
- Size : nombre d'éléments (>1 si tableau)
- MPI_data_type : le type de donnée (ex : MPI_INTEGER)
- MPI_reduction_operation: type d'opération à effectuer pour la réduction (ex: MPI_SUM)
- **Destination** : le processus qui va recevoir les données réduites



Communication collective : réduction grâce à MPI_Reduce (C/C++) Collective communication

MPI_Reduce est appelée par les processus expéditeurs et destinataires en même temps



```
MPI_Reduce(send_value, &recv_value, size, MPI_data_type,
MPI_reduction_operation, destination, communicator);
```

- send_value (const void *): la valeur à envoyer par chaque processus
- recv_value (void *): la valeur reçue suite aux échanges et à la réduction par le destinataire seulement
- Size : nombre d'éléments (>1 si tableau)
- MPI_data_type (MPI_Datatype) : le type de donnée (ex : MPI_INT)
- MPI_reduction_operation (MPI_Op): type d'opération à effectuer pour la réduction (ex: MPI_SUM)
- **Destination** : le processus qui va recevoir les données réduites



Communication collective : opération de réduction

Collective communication

Il existe de multiple opérations de réduction disponibles (MPI_reduction_operation) :

- MPI_SUM : Somme l'ensemble des données
- MPI_PROD : multiplication des données
- MPI_MAX : maximum des valeurs
- MPI_MIN: minimum des valeurs

...



Communication collective : exemple d'utilisation de MPI_REDUCE Collective communication

Réduction d'une simple variable réelle double précision



.f90

```
Real(8) :: rank_value
Real(8) :: reduction_value
Integer :: ierror

rank_value = rank
! Addition de l'ensemble des rank_value dans le processus 0

Call MPI_REDUCE(rank_value, reduction_value, 1 & MPI_DOUBLE_PRECISION, MPI_SUM, 0, & MPI_COMM_WORLD, ierror)
```

Communication collective : exemple d'utilisation de MPI_Reduce (C/C++)

Collective communication

Réduction d'une simple variable réelle double précision



.cpp

Communication collective : exemple d'utilisation de MPI_REDUCE Collective communication

Réduction d'un tableau d'entiers avec multiplication de toutes les valeurs



.f90

Communication collective : exemple d'utilisation de MPI_Reduce (C/C++)

Collective communication

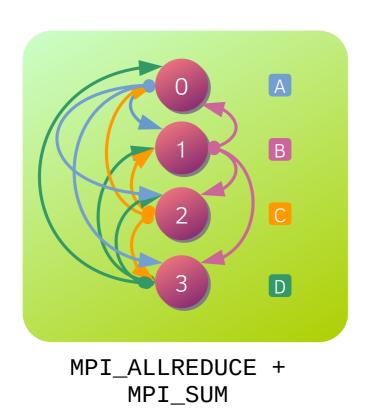
Réduction d'un tableau d'entiers avec multiplication de toutes les valeurs

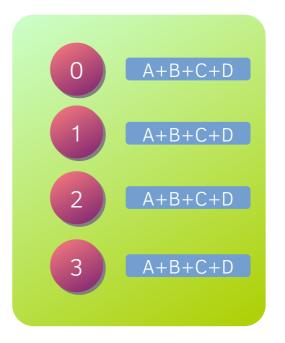


.cpp

Communication collective : réduction grâce à MPI_Allreduce Collective communication

 Envoi de données réparties sur plusieurs processus vers tous les processus avec une opération de réduction réalisée simultanément





Nouvelle répartition des données et addition



https://www.open-mpi.org/doc/v4.0/man3/MPI_Allreduce.3.php

Communication collective: réduction grâce à MPI_ALLREDUCE (Fortran95)

Collective communication

 MPI_ALLREDUCE est appelée par les processus expéditeurs et destinataires en même temps



MPI_ALLREDUCE(send_value, recv_value, size, MPI_data_type,
MPI_reduction_operation, communicator, ierror)

- send_value : la valeur à envoyer par chaque processus
- recv_value : la valeur reçue suite aux échanges et à la réduction par le destinataire seulement
- Size : nombre d'éléments (>1 si tableau)
- MPI_data_type : le type de donnée (ex : MPI_INTEGER)
- MPI_reduction_operation: type d'opération à effectuer pour la réduction (ex: MPI_SUM)



Communication collective : réduction grâce à MPI_Allreduce (C/C++)

Collective communication

 MPI_Allreduce est appelée par les processus expéditeurs et destinataires en même temps

```
f90
```

```
MPI_Allreduce(send_value, &recv_value, size, MPI_data_type,
MPI_reduction_operation, communicator);
```

- send_value : la valeur à envoyer par chaque processus
- recv_value : la valeur reçue suite aux échanges et à la réduction par le destinataire seulement
- Size : nombre d'éléments (>1 si tableau)
- MPI_data_type : le type de donnée (ex : MPI_INTEGER)
- MPI_reduction_operation: type d'opération à effectuer pour la réduction (ex: MPI_SUM)



Exercice n°5 : Utilisation de la communication collective MPI_REDUCE



Rendez vous dans le dossier de l'exercice n°5 appelé 5_reduce_com



> cd exercises/mpi/5_reduce_com

 Ouvrez les instructions contenues dans le fichier README.md avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

Fonctions supplémentaires



- Toutes les fonctions présentées ont un équivalent non-bloquant : MPI_Igather, MPI_Iscatter, MPI_Ireduce...
- D'autres variantes de communications collectives sont à découvrir dans le cours de l'IDRIS et la documentation MPI

Communications collectives MPI

A ce stade du cours, vous savez maintenant :

- Effectuer des communications collectives
- Effectuer des réductions

Introduction au parallélisme par échange de message via MPI 5) Topologie cartésienne

Décomposition de domaine cartésienne

En calcul scientifique, il est courant de décomposer le domaine d'étude (grille, matrice) en sous-domaines, chaque sous-domaine étant alors géré par un processus MPI unique.

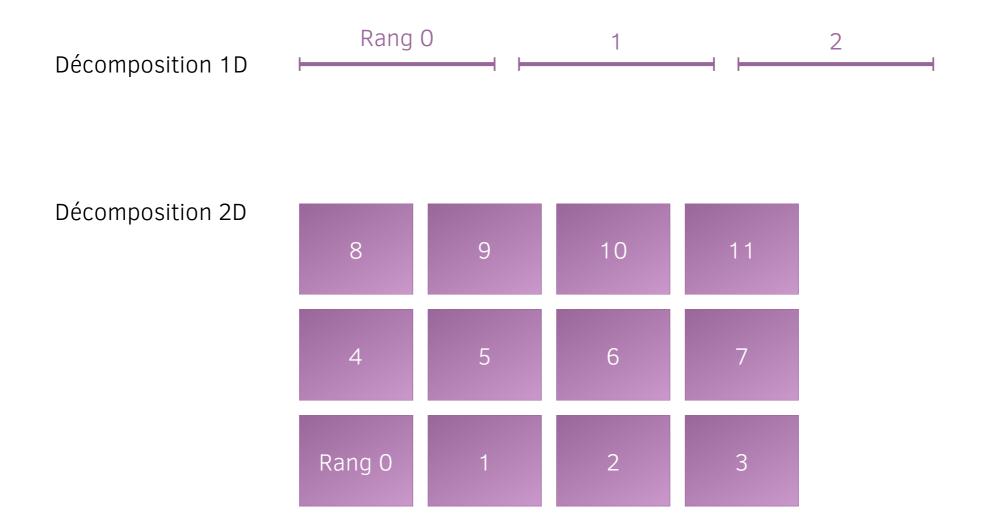
Sur grille régulière et structurée, une approche simple et classique consiste à diviser le domaine en blocs réguliers possédant alors dans sa mémoire locale une partie unique de la grille globale.

Méthode de décomposition cartésienne



Il s'agit d'un exemple typique de parallélisme de donnée

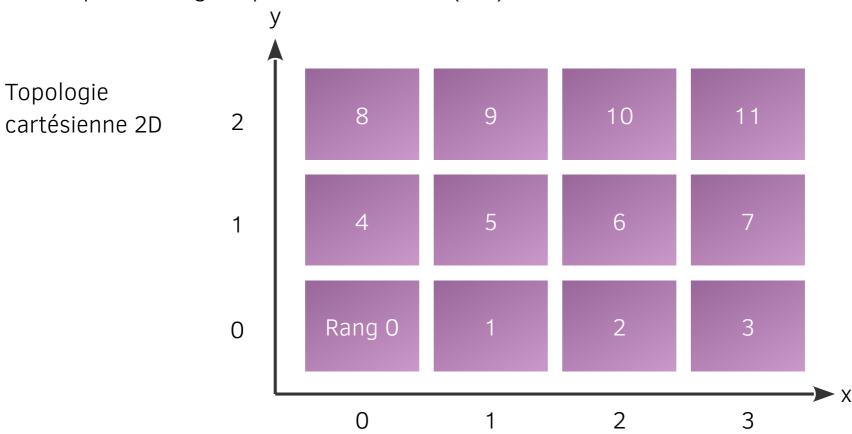
Décomposition de domaine cartésienne



Décomposition de domaine cartésienne : coordonnées

Une topologie cartésienne a besoin de :

- Coordonnées pour situer les processus (bloc) dans l'espace cartésien
- De rangs pour chaque processus en adéquation avec la topologie cartésienne
- exemple : le rang 5 a pour coordonnées (1,1)



Décomposition de domaine cartésienne : création



Deux solutions pour mettre en place une topologie cartésienne :

- Le faire à la main
- Faire appel aux fonctions MPI conçues pour ça

Décomposition de domaine cartésienne : création via MPI_Cart_create (Fortran95)

MPI_CART_CREATE permet de définir une topologie cartésienne à partir d'un ancien communicateur (celui par défaut par exemple MPI_COMM_WORLD)



```
MPI_CART_CREATE(old_communicator, dimension, ranks_per_adirection, periodicity, reorganisation,cartesian_communicator,ierror)
```

- old_communicator : ancien communicateur (MPI_COMM_WORLD par exemple)
- dimension (entier): dimension de la topologie (2 pour 2D par exemple)
- ranks_per_direction (tableau d'entier) : le nombre de rangs dans chaque dimension
- Periodicity (tableau de booléens) : permet de définir les directions périodiques (true)
- Reorganisation (booléen): réorganisation des rangs pour optimiser les échanges (true)
- cartesian_communicator (entier) : nouveau communicateur renvoyé par la fonction qui vient remplacer l'ancien communicateur.



https://www.open-mpi.org/doc/v4.0/man3/MPI_Cart_create.3.php

Décomposition de domaine cartésienne : création via MPI_Cart_create (C/C++)

MPI_Cart_create permet de définir une topologie cartésienne à partir d'un ancien communicateur (celui par défaut par exemple MPI_COMM_WORLD)



```
MPI_Cart_create(old_communicator, dimension, ranks_per_adirection, periodicity, reorganisation,cartesian_communicator);
```

- old_communicator (MPI_Comm) : ancien communicateur (MPI_COMM_WORLD par exemple)
- dimension (int): dimension de la topologie (2 pour 2D par exemple)
- ranks_per_direction (int *): le nombre de rangs dans chaque dimension
- Periodicity (int *): permet de définir les directions périodiques
- Reorganisation (int): réorganisation des rangs pour optimiser les échanges
- cartesian_communicator (MPI_Comm *) : nouveau communicateur renvoyé par la fonction qui vient remplacer l'ancien communicateur.



https://www.open-mpi.org/doc/v4.0/man3/MPI_Cart_create.3.php

Décomposition de domaine cartésienne : création



Comme pour n'importe quel communicateur, on peut récupérer les rangs dans le communicateur cartésien (cartesian_communicator) avec MPI_COMM_RANK

Décomposition de domaine cartésienne : récupérer les coordonnées d'un rang via MPI_CART_COORDS (Fortran95)

 MPI_CART_COORDS permet de récupérer les coordonnées d'un rang donné dans la topologie cartésienne.



CALL MPI_CART_COORDS(cartesian_communicator, rank, dimension, & rank_coordinates, ierror)

- **Dimension** (entier): dimension de la topologie (2 pour 2D par exemple)
- ranks_coordinates (tableau d'entier) : les coordonnées du rang rank dans cartesian communicator



Décomposition de domaine cartésienne : récupérer les coordonnées d'un rang via MPI_CART_COORDS (C/C++)

 MPI_Cart_coords permet de récupérer les coordonnées d'un rang donné dans la topologie cartésienne.



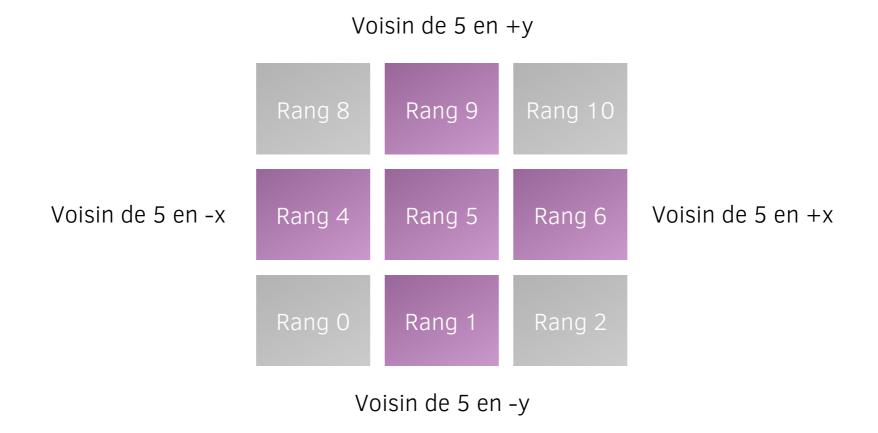
```
MPI_Cart_coords(cartesian_communicator, rank, dimension, rank_coordinates);
```

- Rank (int): rang du processus MPI
- **Dimension** (int): dimension de la topologie (2 pour 2D par exemple)
- ranks_coordinates (int *) : les coordonnées du rang rank dans cartesian_communicator



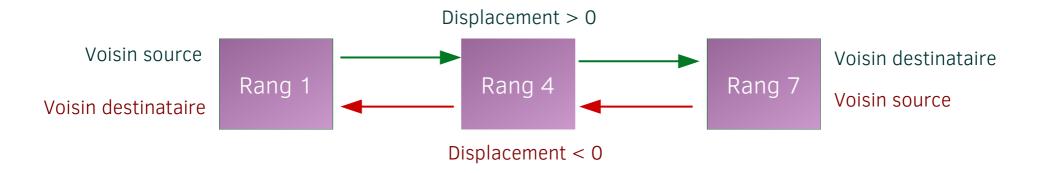
Décomposition de domaine cartésienne : les voisins

 Chaque processus doit être en mesure de récupérer le rang de ses voisins dans la topologie cartésienne pour d'éventuelles communications.



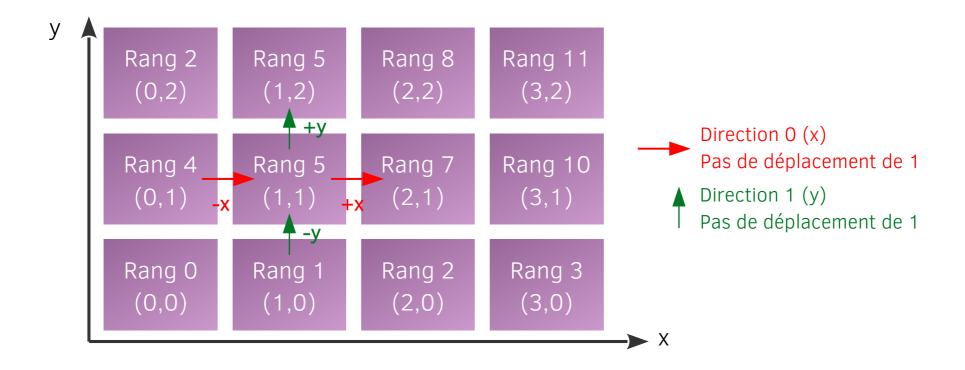
Décomposition de domaine cartésienne : récupérer les rangs des voisins via MPI_CART_SHIFT

MPI_CART_SHIFT permet de récupérer les rangs voisins d'un rang donné en spécifiant une direction et un sens de déplacement. On récupère 2 voisins dans la philosophie MPI_Sendrecv : un rang source et un rang destinataire.

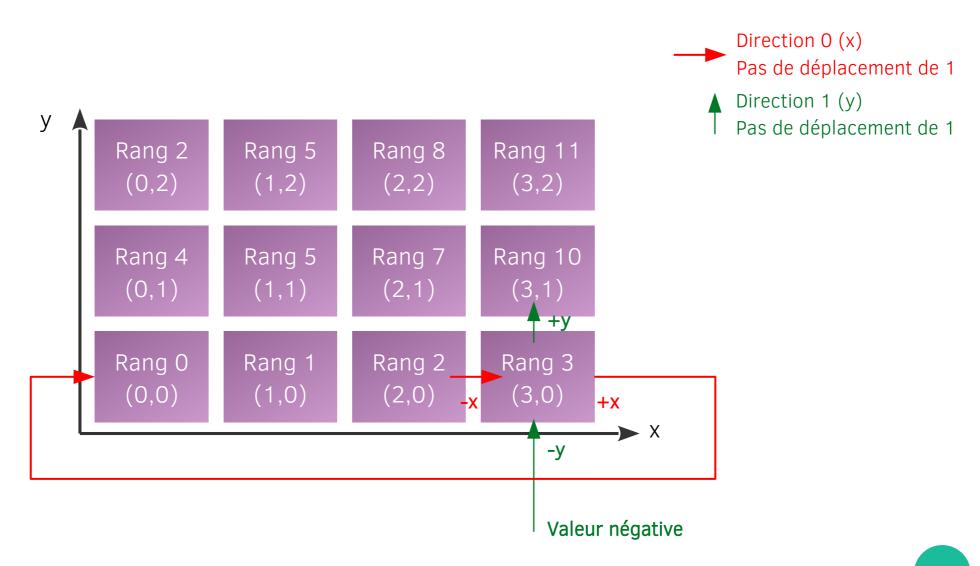




Exemple de topologie cartésienne 2D



Exemple de topologie cartésienne 2D : notion de périodicité



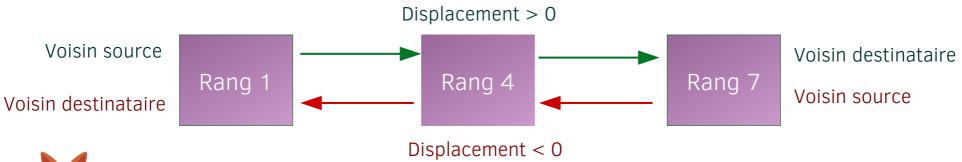
Décomposition de domaine cartésienne : récupérer les rangs des voisins via MPI_CART_SHIFT

MPI_CART_SHIFT permet de récupérer les rangs voisins d'un rang donné

```
.f90
```

```
MPI_CART_SHIFT(cartesian_communicator, direction, displacement, rank_neighbors_dest, ierror)
```

- direction (integer): 1 pour la première coordonnée, 2 pour la deuxième coordonnée
- **Displacement** (integer): pas de déplacement dans la direction souhaitée, si > 0 déplacement vers les coordonnées supérieures, si < 0 vers les coordonnées inférieures
- rank_neighbord_source : si displacement > 0, correspond au voisin source
- rank_neighbord_dest: si displacement > 0, correspond au voisin destinataire



0 0

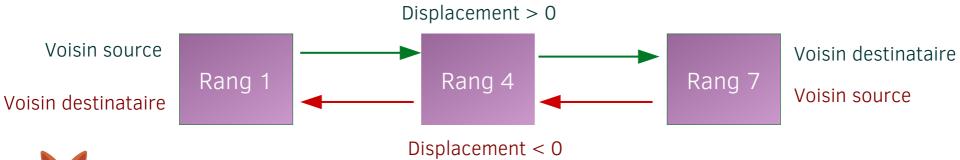
https://www.open-mpi.org/doc/v2.0/man3/MPI_Cart_shift.3.php

Décomposition de domaine cartésienne : récupérer les rangs des voisins via MPI_CART_SHIFT (C/C++)

MPI_Cart_shift permet de récupérer les rangs voisins d'un rang donné

```
.cpp
```

- direction (int): 1 pour la première coordonnée, 2 pour la deuxième coordonnée
- **Displacement** (int): pas de déplacement dans la direction souhaitée, si > 0 déplacement vers les coordonnées supérieures, si < 0 vers les coordonnées inférieures
- rank_neighbord_source : si displacement > 0, correspond au voisin source
- rank_neighbord_dest: si displacement > 0, correspond au voisin destinataire



0 0

https://www.open-mpi.org/doc/v2.0/man3/MPI_Cart_shift.3.php

Exemple de topologie cartésienne 2D (Fortran95)



```
Integer, dimension(2) :: ranks_per_direction = (/4, 3/)
Logical, dimension(2) :: periodicity = (/ .true., .true. /)
           :: reorganisation = .true.
Logical
Integer
Integer, dimension(2) :: rank_coordinates
                     :: rank_neighbors_mx, rank_neighbors_px
Integer
                      :: rank_neighbors_my, rank_neighbors_py
Integer
Call MPI_INIT(ierror)
Call MPI_CART_CREATE(MPI_COMM_WORLD, 2, ranks_per_direction, periodicity,
                     reorganisation, cartesian communicator, ierror)
Call MPI_COMM_RANK(cartesian_communicator, rank, ierror)
Call MPI_CART_COORDS(cartesian_communicator, rank, 2, rank_coordinates, ierror)
CALL MPI_CART_SHIFT(cartesian_communicator, 1, 1, &
                    rank_neighbors_my, rank_neighbors_py, ierror)
CALL MPI_CART_SHIFT(cartesian_communicator, 0, 1, &
                    rank_neighbors_mx, rank_neighbors_px, ierror)
```

Exemple de topologie cartésienne 2D (C/C++)



```
int ranks_per_direction[2] = {4, 3};
int periodicity[2] = \{1, 1\};
int reorganisation = 1;
MPI_Comm cartesian_communicator ;
int rank_coordinates[2] ;
int rank_neighbors_mx, rank_neighbors_px ;
int rank_neighbors_my, rank_neighbors_py ;
ierror = MPI_Init(ierror)
Ierror = MPI_Cart_create(MPI_COMM_WORLD, 2, ranks_per_direction, periodicity,
                     reorganisation, & cartesian communicator);
ierror = MPI_Comm_rank(cartesian_communicator, rank) ;
ierror = MPI_Cart_coords(cartesian_communicator, rank, 2, &rank_coordinates);
ierror = MPI_Cart_shift(cartesian_communicator, 1, 1,
                    &rank_neighbors_my, &rank_neighbors_py);
ierror = MPI_Cart_shift(cartesian_communicator, 0, 1,
                    &rank_neighbors_mx, &rank_neighbors_px);
```

Exercice n°6 : Création d'une topologie cartésienne



• Rendez vous dans le dossier de l'exercice n°6 appelé 6_cartesian_com



> cd exercises/mpi/6_cartesian_com

 Ouvrez les instructions contenues dans le fichier README.md avec votre éditeur de fichier favori (vim, emacs, atom, gedit...) ou visualisez directement les instructions sur le GitLab.

Décomposition de domaine cartésienne

A ce stade du cours, vous savez maintenant :

- Créer un communicateur cartésien pour décomposer vos données
- Utiliser les fonctions liées à la décomposition cartésienne